

# Méthodes de Monte Carlo et inférence bayésienne

## Introduction

Pierre Gloaguen

[pierre.gloaguen@agroparistech.fr](mailto:pierre.gloaguen@agroparistech.fr)

# Déroulé du cours

- ▶ 7 séances de 3h;
- ▶ Chaque début de séance consacré aux questions et à la présentation du cours;
- ▶ TD en autonomie ensuite (avec réponse aux questions);
- ▶ Evaluation en contrôle continu (exercices à rendre);

# Objectifs de cette 1ère séance

- ▶ Introduction et motivation du sujet du cours;
- ▶ Principe des méthodes de Monte Carlo;
- ▶ Premiers exercices et implémentation sous R.

## Introduction et motivations

# Modélisation statistique

- ▶ Formulation probabiliste d'un problème:
  - ▶ *On suppose que les données sont les réalisations de variables aléatoires telles que ...;*
- ▶ Quantification de l'incertitude:
  - ▶ *d'après le modèle posé, la probabilité que tel événement arrive est de ...;*
- ▶ Recours permanent au **calcul de probabilités**;

## Exemple immédiat

- ▶ Test d'hypothèse: On veut tester une hypothèse  $H_0$  contre une hypothèse  $H_1$ 
  - ▶ *Ex: Comparaison de moyennes de deux échantillons Gaussiens;*
- ▶ On construit une statistique de test  $T$ ;
- ▶ Décision binaire, pour un risque de première espèce  $\alpha$ , on définit un zone de rejet  $\mathcal{R}$ , telle que

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$$

## Exemple immédiat

- ▶ Test d'hypothèse: On veut tester une hypothèse  $H_0$  contre une hypothèse  $H_1$ 
  - ▶ *Ex: Comparaison de moyennes de deux échantillons Gaussiens;*
- ▶ On construit une statistique de test  $T$ ;
- ▶ Décision binaire, pour un risque de première espèce  $\alpha$ , on définit un zone de rejet  $\mathcal{R}$ , telle que

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$$

### Rappel:

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \mathbb{E}_{H_0}[\mathbf{1}_{T \in \mathcal{R}}]$$

- ▶ On doit donc être capable d'évaluer une espérance (ici, la probabilité d'évènements) sous  $H_0$  pour construire notre test.

# Exemple de modèle statistique: Biomasse d'une population de poisson

**Ce qu'on connaît**

Captures  $C$



Observations scientifiques  $Y$



**Quantité d'intérêt**

Biomasse de poisson  $X$





# Modèle probabiliste d'observation de la dynamique de population

$$X_{t+1} = \left( X_t + rX_t \left( 1 - \frac{X_t}{K} \right) - C_t \right) \exp(\varepsilon_{t+1}), \text{ Biomasse cachée}$$

$$Y_t | X_t = qX_t \exp(\nu_t), \quad C_t \text{ Observations}$$

$$\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N} \left( -\sigma^2/2, \sigma^2 \right), \quad \nu_t \stackrel{i.i.d}{\sim} \mathcal{N} \left( -\sigma_{\text{obs}}^2/2, \sigma_{\text{obs}}^2 \right).$$

- ▶  $X_t$ : Biomasse à l'année  $t$  (non observée);
- ▶  $Y_t$ : Abundance observée à l'année  $t$ ;
- ▶  $C_t$ : Captures à l'année  $t$ ;
- ▶  $K$ : Capacité d'accueil du milieu (paramètre);
- ▶  $r$ : Taux de croissance de la population (paramètre);
- ▶  $\sigma, \sigma_{\text{obs}}$ : Paramètres de l'aléa;
- ▶  $q$ : Détectabilité (paramètre);

# Questions classiques d'inférence

## Questions classiques d'inférence

- Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);



# Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);

# Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);
  - ▶ Estimateur Bayésien: Nécessite un calcul d'espérance.

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);
  - ▶ Estimateur Bayésien: Nécessite un calcul d'espérance.

Ces espérances n'ont, en général, pas d'expressions directes!

# Méthodes de Monte Carlo

# Méthodes de Monte Carlo

- ▶ **But:** Approcher des espérances (intégrales) en utilisant des simulations probabilistes;

# Méthodes de Monte Carlo

- ▶ **But:** Approcher des espérances (intégrales) en utilisant des simulations probabilistes;
- ▶ **Idée:** La loi des grands nombres! La moyenne empirique d'une variable aléatoire va tendre, si on répète l'expérience, vers la moyenne théorique.

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?



## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?
- ▶ À quel point peut être confiant en notre réponse?

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?
- ▶ À quel point peut être confiant en notre réponse?
- ▶ Encore faut il savoir lancer le dé!

# Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);

# Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?

# Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?
- ▶ Une méthode d'inférence dépendante de la simulation: l'inférence bayésienne;

# Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?
- ▶ Une méthode d'inférence dépendante de la simulation: l'inférence bayésienne;
- ▶ Une extension nécessaire, les Méthodes de Monte Carlo par chaîne de Markov (MCMC).

# Prérequis

- ▶ Résultats statistiques asymptotiques:
  - ▶ Loi des grands nombres, théorème central limite, lemme de Slutsky, Delta méthode.
- ▶ Chaînes de Markov:
  - ▶ Loi de transition, irréductibilité, périodicité, mesure invariante
  - ...
- ▶ Logiciel R
  - ▶ Logiciel R installé ainsi que l'IDE Rstudio.
  - ▶ Connaissance minimale du langage (boucles, fonctions, graphiques de base. . . ).