

# Méthodes de Monte Carlo et inférence bayésienne

## Introduction

Pierre Gloaguen

pierre.gloaguen@agroparistech.fr

## Déroulé du cours

- ▶ 7 séances de 3h;
- ▶ Chaque début de séance consacré aux questions et à la présentation du cours;
- ▶ TD en autonomie ensuite (avec réponse aux questions);
- ▶ Evaluation en contrôle continu (exercices à rendre);

## Objectifs de cette 1ère séance

- ▶ Introduction et motivation du sujet du cours;
- ▶ Principe des méthodes de Monte Carlo;
- ▶ Premiers exercices et implémentation sous R.

## Introduction et motivations

# Modélisation statistique

- ▶ Formulation probabiliste d'un problème:
  - ▶ *On suppose que les données sont les réalisations de variables aléatoires telles que ...;*
- ▶ Quantification de l'incertitude:
  - ▶ *d'après le modèle posé, la probabilité que tel événement arrive est de ...;*
- ▶ Recours permanent au **calcul de probabilités**;

## Exemple immédiat

- ▶ Test d'hypothèse: On veut tester une hypothèse  $H_0$  contre une hypothèse  $H_1$ 
  - ▶ Ex: *Comparaison de moyennes de deux échantillons Gaussiens;*
- ▶ On construit une statistique de test  $T$ ;
- ▶ Décision binaire, pour un risque de première espèce  $\alpha$ , on définit une zone de rejet  $\mathcal{R}$ , telle que

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$$

## Exemple immédiat

- ▶ Test d'hypothèse: On veut tester une hypothèse  $H_0$  contre une hypothèse  $H_1$ 
  - ▶ Ex: *Comparaison de moyennes de deux échantillons Gaussiens;*
- ▶ On construit une statistique de test  $T$ ;
- ▶ Décision binaire, pour un risque de première espèce  $\alpha$ , on définit une zone de rejet  $\mathcal{R}$ , telle que

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$$

**Rappel:**

$$\mathbb{P}_{H_0}(T \in \mathcal{R}) = \mathbb{E}_{H_0}[\mathbf{1}_{T \in \mathcal{R}}]$$

- ▶ On doit donc être capable d'évaluer une espérance (ici, la probabilité d'événements) sous  $H_0$  pour construire notre test.

Exemple de modèle statistique: Biomasse d'une population de poisson

Ce qu'on connaît

Captures  $C$



Observations scientifiques  $Y$



Quantité d'intérêt

Biomasse de poisson  $X$



## Modèle probabiliste d'observation de la dynamique de population

$$X_{t+1} = \left( X_t + r X_t \left( 1 - \frac{X_t}{K} \right) - C_t \right) \exp(\varepsilon_{t+1}), \text{ Biomasse cachée}$$

$$Y_t | X_t = q X_t \exp(\nu_t), \text{ } C_t \text{ Observations}$$

$$\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N}(-\sigma^2/2, \sigma^2), \quad \nu_t \stackrel{i.i.d}{\sim} \mathcal{N}(-\sigma_{\text{obs}}^2/2, \sigma_{\text{obs}}^2).$$

- ▶  $X_t$ : Biomasse à l'année  $t$  (non observée);
- ▶  $Y_t$ : Abondance observée à l'année  $t$ ;
- ▶  $C_t$ : Captures à l'année  $t$ ;
- ▶  $K$ : Capacité d'accueil du milieu (paramètre);
- ▶  $r$ : Taux de croissance de la population (paramètre);
- ▶  $\sigma, \sigma_{\text{obs}}$ : Paramètres de l'aléa;
- ▶  $q$ : DéTECTabilité (paramètre);

## Questions classiques d'inférence

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);
  - ▶ Estimateur Bayésien: Nécessite un calcul d'espérance.

## Questions classiques d'inférence

- ▶ Pour un tel modèle, étant donnée une population initiale  $X_0$ , quelle est la moyenne attendue du nombre de poissons au bout de 10 ans si on se fixe une quantité de captures?
  - ▶  $\mathbb{E}[X_{10}|X_0]$ ?
- ▶ Etant données des observations sur 10 années, et en supposant tous les paramètres connus, que puis je dire sur la quantité de poissons qu'il y avait durant ces 10 ans?
  - ▶  $\mathbb{E}[X_{0:10}|Y_{0:10}]$ ?
- ▶ Etant données des observations, que puis je dire sur la valeur des paramètres de dynamique de population?
  - ▶ Inférence des paramètres:
  - ▶ Méthode des moments (nécessite un calcul d'espérance);
  - ▶ Méthode du maximum de vraisemblance (nécessite ici un calcul d'espérance);
  - ▶ Estimateur Bayésien: Nécessite un calcul d'espérance.

Ces espérances n'ont, en général, pas d'expressions directes!

# Méthodes de Monte Carlo

## Méthodes de Monte Carlo

- ▶ **But:** Approcher des espérances (intégrales) en utilisant des simulations probabilistes;

## Méthodes de Monte Carlo

- ▶ **But:** Approcher des espérances (intégrales) en utilisant des simulations probabilistes;
- ▶ **Idée:** La loi des grands nombres! La moyenne empirique d'une variable aléatoire va tendre, si on répète l'expérience, vers la moyenne théorique.

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?
- ▶ À quel point peut être confiant en notre réponse?

## Exemple

On dispose d'un dé à 6 faces et seulement de ce dé. Comment peut on essayer de savoir s'il est biaisé?

- ▶ Si on lance le dé suffisamment de fois, on obtient une information;
- ▶ Combien de fois faut il lancer le dé pour avoir une idée précise?
- ▶ À quel point peut être confiant en notre réponse?
- ▶ Encore faut il savoir lancer le dé!

## Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);

## Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?

## Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?
- ▶ Une méthode d'inférence dépendante de la simulation:  
l'inférence bayésienne;

## Programme du cours

- ▶ Présentation formelle des méthodes de Monte Carlo pour le calcul d'intégrales;
- ▶ Application directe en statistique classique (évaluation d'une probabilité, aide à la décision);
- ▶ Comment peut on simuler des variables aléatoires génériques (avec un ordinateur)?
- ▶ Une méthode d'inférence dépendante de la simulation:  
l'inférence bayésienne;
- ▶ Une extension nécessaire, les Méthodes de Monte Carlo par chaîne de Markov (MCMC).

# Prérequis

- ▶ Résultats statistiques asymptotiques:
  - ▶ Loi des grands nombres, théorème central limite, lemme de Slutsky, Delta méthode.
- ▶ Chaînes de Markov:
  - ▶ Loi de transition, irréductibilité, périodicité, mesure invariante
  - ...
- ▶ Logiciel R
  - ▶ Logiciel R installé ainsi que l'IDE Rstudio.
  - ▶ Connaissance minimale du langage (boucles, fonctions, graphiques de base...).

# Principe des méthodes de Monte Carlo

Pierre Gloaguen


22/03/2020

## Exemple introductif (1)

Soit  $g$  une fonction sur  $\mathbb{R}$  et  $a < b$  deux réels.

Supposons que l'on souhaite calculer une intégrale (finie) du type

$$I = \int_a^b g(x)dx$$



## Exemple introductif (2)

$$I = \int_a^b g(x)dx$$

## Exemple introductif (2)

$$\begin{aligned} I &= \int_a^b g(x) dx \\ &\stackrel{:=\varphi(x)}{=} \int_{\mathbb{R}} \overbrace{(b-a)g(x)}^{\mathbf{1}_{a \leq x \leq b}} \frac{1}{b-a} dx \end{aligned}$$

## Exemple introductif (2)

$$\begin{aligned} I &= \int_a^b g(x)dx \\ &\stackrel{\text{:=}\varphi(x)}{=} \int_{\mathbb{R}} \overbrace{(b-a)g(x)}^{\mathbf{1}_{a \leq x \leq b}} \frac{1}{b-a} dx \\ &= \mathbb{E}[\varphi(X)], \text{ où } X \sim \mathcal{U}[a, b]. \end{aligned}$$

## Exemple introductif (2)

$$\begin{aligned} I &= \int_a^b g(x)dx \\ &\stackrel{\text{:=}\varphi(x)}{=} \int_{\mathbb{R}} \overbrace{(b-a)g(x)}^{\text{:=}\varphi(x)} \frac{\mathbf{1}_{a \leq x \leq b}}{b-a} dx \\ &= \mathbb{E}[\varphi(X)], \text{ où } X \sim \mathcal{U}[a, b]. \end{aligned}$$

### Estimateur de Monte Carlo

On fixe un entier  $M > 0$ . On simule un échantillon  $X_1, \dots, X_M$  selon  $X \sim \mathcal{U}[a, b]$ , on pose alors l'estimateur:

$$\hat{I}_M = \frac{1}{M} \sum_{k=1}^M \varphi(X_k)$$

## Exemple introductif (2)

$$\begin{aligned} I &= \int_a^b g(x)dx \\ &\stackrel{\text{:=}\varphi(x)}{=} \int_{\mathbb{R}} \overbrace{(b-a)g(x)}^{\mathbf{1}_{a \leq x \leq b}} \frac{1}{b-a} dx \\ &= \mathbb{E}[\varphi(X)], \text{ où } X \sim \mathcal{U}[a, b]. \end{aligned}$$

### Estimateur de Monte Carlo

On fixe un entier  $M > 0$ . On simule un échantillon  $X_1, \dots, X_M$  selon  $X \sim \mathcal{U}[a, b]$ , on pose alors l'estimateur:


$$\hat{I}_M = \frac{1}{M} \sum_{k=1}^M \varphi(X_k)$$

### Remarques

- ▶  $M$  est appelé **effort de Monte Carlo**;
- ▶ On suppose pour le moment qu'on **sait simuler selon**  $\mathcal{U}[a, b]$ ;
- ▶ L'estimateur de  $I$  est une **variable aléatoire**.

## Exemple introductif (3)

**Estimations Monte Carlo de  $\lambda$  (50 réplicats)**



## Cas générique

On veut calculer une intégrale

$$I = \int_{\mathbb{R}^d} \varphi(x) f(x) dx$$

où  $f$  est une fonction positive, telle que  $\int_{\mathbb{R}^d} f(x) dx = 1$ , alors on se sert du fait que

$$I = \mathbb{E}[\varphi(X)]$$

où  $X$  est une variable aléatoire de densité  $f$ .

### Estimateur de Monte Carlo

On fixe un entier  $M > 0$ . On simule un échantillon  $X_1, \dots, X_N$  selon  $X \sim f(\cdot)$ , on pose alors l'estimateur:

$$\hat{I}_N = \frac{1}{M} \sum_{k=1}^M \varphi(X_k)$$

## Pourquoi?

Les  $\varphi(X_1), \dots, \varphi(X_N)$  sont des variables aléatoires i.i.d. d'espérance  $\mathbb{E}[\varphi(X)]$  finie, avec  $X \sim f(\cdot)$ .

## Pourquoi?

Les  $\varphi(X_1), \dots, \varphi(X_N)$  sont des variables aléatoires i.i.d. d'espérance  $\mathbb{E}[\varphi(X)]$  finie, avec  $X \sim f(\cdot)$ .

Loi des grands nombres:

$$\frac{\varphi(X_1) + \dots + \varphi(X_N)}{N} \xrightarrow[N \rightarrow \infty]{\text{p.s.}} \mathbb{E}[\varphi(X)]$$

# Propriétés

## Sans biais

$$\mathbb{E}[\hat{I}_N] = \frac{1}{M} \sum_{k=1}^M \mathbb{E}[\varphi(X_k)] \stackrel{\text{id. distrib}}{=} \mathbb{E}[\varphi(X)] = I$$

# Propriétés

## Sans biais

$$\mathbb{E}[\hat{I}_N] = \frac{1}{M} \sum_{k=1}^M \mathbb{E}[\varphi(X_k)] \stackrel{\text{id. distrib}}{=} \mathbb{E}[\varphi(X)] = I$$

**Variance** Si  $\mathbb{V}[\varphi(X)] < \infty$

$$\mathbb{V}[\hat{I}_N] \stackrel{\text{ind.}}{=} \frac{1}{M^2} \sum_{k=1}^M \mathbb{V}[\varphi(X_k)] \stackrel{\text{id. distrib}}{=} \frac{1}{M} \mathbb{V}[\varphi(X)]$$

# Propriétés

## Sans biais

$$\mathbb{E}[\hat{I}_N] = \frac{1}{M} \sum_{k=1}^M \mathbb{E}[\varphi(X_k)] \stackrel{\text{id. distrib}}{=} \mathbb{E}[\varphi(X)] = I$$

**Variance** Si  $\mathbb{V}[\varphi(X)] < \infty$


$$\mathbb{V}[\hat{I}_N] \stackrel{\text{ind.}}{=} \frac{1}{M^2} \sum_{k=1}^M \mathbb{V}[\varphi(X_k)] \stackrel{\text{id. distrib}}{=} \frac{1}{M} \mathbb{V}[\varphi(X)]$$

**Loi** La loi des grands nombres nous donne la loi asymptotique

$$\sqrt{M} (\hat{I}_N - I) \xrightarrow[M \rightarrow \infty]{\text{Loi}} \mathcal{N}(0, \mathbb{V}[\varphi(X)])$$

## Loi de l'estimateur

- ▶ 100 répliques d'échantillons Monte Carlo de taille  $M = 1000$ .



## Intervalle de confiance

On note

$$\sigma^2 = \mathbb{V}[\varphi(X)].$$

Ainsi, en notant  $z_\alpha$  le quantile d'ordre  $\alpha \in ]0, 1[$  de la loi  $\mathcal{N}(0, 1)$ , si on définit l'intervalle aléatoire

$$J_M = \left[ \hat{l}_M - z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{M}}; \hat{l}_M + z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{M}} \right]$$

Alors,

$$\mathbb{P}(J_M \ni l) \xrightarrow[M \rightarrow \infty]{} 1 - \alpha$$

$J_M$  est donc un intervalle de confiance asymptotique au niveau  $1 - \alpha$  pour la valeur de  $l$ .

## Intervalle de confiance (2)


En pratique cependant, cet intervalle n'est pas calculable car  $\sigma^2$  est inconnu

On dispose cependant d'un estimateur consistant de  $\sigma^2$  donné par

$$\hat{\sigma}_M^2 = \frac{1}{M} \sum_{k=1}^M (\varphi(X_k) - \hat{I}_M)^2$$

- ▶ Dans l'expression précédente, on remplace  $\sigma^2$  par son estimateur.
- ▶ Le lemme de Slutski nous assure que les propriétés de  $J_M$  restent vraies.

## Intervalle de confiance (3)



## Comparaison avec l'intégration numérique

L'objectif présenté ici est de calculer, en dimension  $d$ , une intégrale:

$$\int_{\mathbb{R}^d} g(x) dx$$

- Calcul possible par méthode numérique (méthode des cubes).

## Comparaison avec l'intégration numérique

L'objectif présenté ici est de calculer, en dimension  $d$ , une intégrale:

$$\int_{\mathbb{R}^d} g(x) dx$$

- Calcul possible par méthode numérique (méthode des cubes).
  - ▶ **Intégration numérique:** Pour une fonction  $g$  de classe  $C^s$ , l'erreur est de l'ordre  $\frac{1}{M^{\frac{s}{d}}}$  (où  $M$  est le nombre d'évaluations de la fonction).
    - ▶ Il faut connaître la régularité de  $g$ !
    - ▶ L'erreur augmente avec la dimension.

## Comparaison avec l'intégration numérique

L'objectif présenté ici est de calculer, en dimension  $d$ , une intégrale:

$$\int_{\mathbb{R}^d} g(x) dx$$

- Calcul possible par méthode numérique (méthode des cubes).

► **Intégration numérique:** Pour une fonction  $g$  de classe  $C^s$ , l'erreur est de l'ordre  $\frac{1}{M^{\frac{s}{d}}}$  (où  $M$  est le nombre d'évaluations de la fonction).

- Il faut connaître la régularité de  $g$ !
- L'erreur augmente avec la dimension.

► **Méthodes Monte Carlo:** Pour les méthodes de Monte Carlo, l'écart type de l'erreur est de l'ordre  $\frac{1}{M^{\frac{1}{2}}}$ .

- Indépendamment de la régularité de  $g$ !
- Indépendamment de la dimension!

Ainsi, ces méthodes deviennent vite avantageuses quand  $d$  est grand.

# Echantillonnage préférentiel

Pierre Gloaguen

02/04/2020

## Années:

- ▶ Premier rendu pour le 13 Avril (exo5 du TD1)
- ▶ À faire en binome (à compléter sur le lien envoyé par mail)
- ▶ Corrections des exos 1 à 4 du TD1 mis en ligne
- ▶ On regardera ces corrections et vos questions aujourd'hui

## Rappel de l'épisode précédent

- ▶ Principes des méthodes de Monte Carlo;
- ▶ Approximation d'intégrales (espérances) par simulation;
- ▶ Fonctionne grâce à la loi des grands nombres, IC grâce au TCL.

# Objectif du cours

- ▶ Présentation de l'échantillonnage préférentiel
  - ▶ Extension naturelle des méthodes de MC simples;
  - ▶ Améliore l'efficacité dans certains cas;
  - ▶ Utile quand on ne sait pas simuler selon une loi donnée;

# Objectif du cours

- ▶ Présentation de l'échantillonnage préférentiel
  - ▶ Extension naturelle des méthodes de MC simples;
  - ▶ Améliore l'efficacité dans certains cas;
  - ▶ Utile quand on ne sait pas simuler selon une loi donnée;
- ▶ Motivation: cas de Monte Carlo problématiques;
- ▶ Définition;
- ▶ Propriétés: Analyse de la variance de ce nouvel estimateur;
- ▶ Illustration.

## Echantillonnage préférentiel


## Exemple problématique:

On veut calculer

$$I = \mathbb{E} [\varphi(X)] = \int_{\mathbb{R}} \varphi(x) f(x) dx$$

où  $X \sim \mathcal{N}(0, 1)$  (de densité  $f(x)$ ) et


$$\varphi(x) = \sin^2(x) e^{-5(x-5)^2}$$




## Estimateur Monte Carlo naturel

On tire  $M = 50000$  points dans une loi  $\mathcal{N}(0, 1)$ , et on calcule la moyenne empirique.

## Résultats obtenus:



# Une trajectoire d'estimation




L'estimation est très instable.

# Estimateur Monte Carlo naturel


Estimation de la variance et intervalle de confiance asymptotique:

**Estimation Monte Carlo Standard**




# Manque de chance?

**Estimation Monte Carlo Standard**



## Origine du problème



On échantillonne loin des régions importantes!

## Echantillonnage préférentiel

On cherche à estimer une intégrale du type:

$$I = \mathbb{E}_f[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x)f(x)dx$$

où  $\mathcal{D}_f \subset \mathbb{R}^d$ , et  $f$  est une densité de probabilité sur  $\mathcal{D}_f$  (donc  $f(x) = 0$  pour  $x \notin \mathcal{D}_f$ ) et  $X$  une v.a. de loi  $f$ .

## Echantillonnage préférentiel

On cherche à estimer une intégrale du type:

$$I = \mathbb{E}_f[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x)f(x)dx$$

où  $\mathcal{D}_f \subset \mathbb{R}^d$ , et  $f$  est une densité de probabilité sur  $\mathcal{D}_f$  (donc  $f(x) = 0$  pour  $x \notin \mathcal{D}_f$ ) et  $X$  une v.a. de loi  $f$ .

Soit  $g$  une densité de probabilité sur  $\mathcal{D}_g \supseteq \mathcal{D}_f$  telle que  $x \in \mathcal{D}_f \Rightarrow g(x) > 0$  et  $Y$  une variable aléatoire de loi  $g$ , alors:

$$I = \int_{\mathcal{D}_f} \varphi(x) \frac{f(x)}{g(x)} g(x)dx$$

## Echantillonnage préférentiel

On cherche à estimer une intégrale du type:

$$I = \mathbb{E}_f[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x)f(x)dx$$

où  $\mathcal{D}_f \subset \mathbb{R}^d$ , et  $f$  est une densité de probabilité sur  $\mathcal{D}_f$  (donc  $f(x) = 0$  pour  $x \notin \mathcal{D}_f$ ) et  $X$  une v.a. de loi  $f$ .

Soit  $g$  une densité de probabilité sur  $\mathcal{D}_g \supseteq \mathcal{D}_f$  telle que  $x \in \mathcal{D}_f \Rightarrow g(x) > 0$  et  $Y$  une variable aléatoire de loi  $g$ , alors:

$$\begin{aligned} I &= \int_{\mathcal{D}_f} \varphi(x) \frac{f(x)}{g(x)} g(x) dx \\ &= \int_{\mathcal{D}_g} \varphi(x) \frac{f(x)}{g(x)} g(x) dx \quad \text{as } x \notin \mathcal{D}_f \Rightarrow f(x) = 0 \end{aligned}$$

## Echantillonnage préférentiel

On cherche à estimer une intégrale du type:

$$I = \mathbb{E}_f[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x)f(x)dx$$

où  $\mathcal{D}_f \subset \mathbb{R}^d$ , et  $f$  est une densité de probabilité sur  $\mathcal{D}_f$  (donc  $f(x) = 0$  pour  $x \notin \mathcal{D}_f$ ) et  $X$  une v.a. de loi  $f$ .

Soit  $g$  une densité de probabilité sur  $\mathcal{D}_g \supseteq \mathcal{D}_f$  telle que  
 $x \in \mathcal{D}_f \Rightarrow g(x) > 0$  et  $Y$  une variable aléatoire de loi  $g$ , alors:

$$\begin{aligned} I &= \int_{\mathcal{D}_f} \varphi(x) \frac{f(x)}{g(x)} g(x) dx \\ &= \int_{\mathcal{D}_g} \varphi(x) \frac{f(x)}{g(x)} g(x) dx \quad \text{as } x \notin \mathcal{D}_f \Rightarrow f(x) = 0 \\ &= \mathbb{E}_g \left[ \varphi(Y) \frac{f(Y)}{g(Y)} \right] \end{aligned}$$

## Echantillonnage préférentiel

Comme estimateur de  $I$ , on peut ainsi proposer l'estimateur:

$$\hat{I}_M^{IS} = \frac{1}{M} \sum_{k=1}^M \frac{f(Y_k)}{g(Y_k)} \varphi(Y_k) = \frac{1}{M} \sum_{k=1}^M W(Y_k) \varphi(Y_k)$$

où  $Y_1, \dots, Y_M$  est un échantillon i.i.d. de variables aléatoires sur  $\mathbb{R}^d$  de densité  $g$ .

## Echantillonnage préférentiel

Comme estimateur de  $I$ , on peut ainsi proposer l'estimateur:

$$\hat{I}_M^{IS} = \frac{1}{M} \sum_{k=1}^M \frac{f(Y_k)}{g(Y_k)} \varphi(Y_k) = \frac{1}{M} \sum_{k=1}^M W(Y_k) \varphi(Y_k)$$

où  $Y_1, \dots, Y_M$  est un échantillon i.i.d. de variables aléatoires sur  $\mathbb{R}^d$  de densité  $g$ .

### Remarques:

- ▶ Comme  $Y_k \sim g$ ,  $g(Y_k)$  est p.s.  $\neq 0$

## Echantillonnage préférentiel

Comme estimateur de  $I$ , on peut ainsi proposer l'estimateur:

$$\hat{I}_M^{IS} = \frac{1}{M} \sum_{k=1}^M \frac{f(Y_k)}{g(Y_k)} \varphi(Y_k) = \frac{1}{M} \sum_{k=1}^M W(Y_k) \varphi(Y_k)$$

où  $Y_1, \dots, Y_M$  est un échantillon i.i.d. de variables aléatoires sur  $\mathbb{R}^d$  de densité  $g$ .

### Remarques:

- ▶ Comme  $Y_k \sim g$ ,  $g(Y_k)$  est p.s.  $\neq 0$
- ▶ La variable aléatoire  $W(Y_k) = \frac{f(Y_k)}{g(Y_k)}$  est appelée **poids d'importance** de  $Y_k$ .

## Echantillonnage préférentiel

Comme estimateur de  $I$ , on peut ainsi proposer l'estimateur:

$$\hat{I}_M^{IS} = \frac{1}{M} \sum_{k=1}^M \frac{f(Y_k)}{g(Y_k)} \varphi(Y_k) = \frac{1}{M} \sum_{k=1}^M W(Y_k) \varphi(Y_k)$$

où  $Y_1, \dots, Y_M$  est un échantillon i.i.d. de variables aléatoires sur  $\mathbb{R}^d$  de densité  $g$ .

### Remarques:

- ▶ Comme  $Y_k \sim g$ ,  $g(Y_k)$  est p.s.  $\neq 0$
- ▶ La variable aléatoire  $W(Y_k) = \frac{f(Y_k)}{g(Y_k)}$  est appelée **poids d'importance** de  $Y_k$ .
- ▶ Quand  $f = g$ , on a l'estimateur MC standard (et chaque poids vaut 1).

## Quel intérêt?

On peut choisir  $g$  afin d'échantillonner dans les zones d'importance!

**Biais:**

$$\begin{aligned}\mathbb{E}_g[\hat{I}_M^{IS}] &= \frac{1}{M} \sum_{k=1}^M \int_{\mathcal{D}_g} \frac{f(x)}{g(x)} \varphi(x) g(x) dx \\ &= \int_{\mathcal{D}_f} f(x) \varphi(x) dx = I\end{aligned}$$

Donc, cet estimateur reste sans biais

## Quel intérêt?

On peut choisir  $g$  afin d'échantillonner dans les zones d'importance!

### Biais:

$$\begin{aligned}\mathbb{E}_g[\hat{l}_M^{IS}] &= \frac{1}{M} \sum_{k=1}^M \int_{\mathcal{D}_g} \frac{f(x)}{g(x)} \varphi(x) g(x) dx \\ &= \int_{\mathcal{D}_f} f(x) \varphi(x) dx = l\end{aligned}$$

Donc, cet estimateur reste sans biais


### Variance:

$$\mathbb{V}_g[\hat{l}_1^{IS}] = \left[ \mathbb{E}_g[(W(Y)\varphi(Y))^2] - l^2 \right] = \int_{\mathcal{D}_g} \frac{(\varphi(y)f(y) - lg(y))^2}{g(y)} dy$$

- ▶ La variance peut être très réduite si  $g(y) \underset{\approx}{\propto} \varphi(y)f(y)!$
- ▶ Ceci peut guider le choix de  $g$ !

## Exemple


$g(x)$  est la densité d'une loi de Student  $\mathcal{T}(3)$ .



## Exemple


```
## Warning: `guides(<scale> = FALSE)` is deprecated. Please  
## "none")` instead.
```

**30 échantillons pondérés d'une Student(3)**




## Estimation de $I$ (et IC asymptotique)

### Estimation par échantillonnage préférentiel



## Comparaison sur cet exemple



# Echantillonnage préférentiel

## Avantages

- ▶ Très utile pour l'estimation de quantités petites (probabilités d'évènements rares).

# Echantillonnage préférentiel

## Avantages

- ▶ Très utile pour l'estimation de quantités petites (probabilités d'évènements rares).
- ▶ Peut amener à une forte réduction de variance

# Echantillonnage préférentiel

## Avantages

- ▶ Très utile pour l'estimation de quantités petites (probabilités d'évènements rares).
- ▶ Peut amener à une forte réduction de variance
- ▶ Peut aussi être utilisé quand on ne sait pas simuler selon  $f$ !

# Echantillonnage préférentiel

## Avantages

- ▶ Très utile pour l'estimation de quantités petites (probabilités d'évènements rares).
- ▶ Peut amener à une forte réduction de variance
- ▶ Peut aussi être utilisé quand on ne sait pas simuler selon  $f$ !

## Attention!

- ▶ Nécessite le choix de  $g$ ! Pas toujours évident (notamment en grande dimension)!

# Echantillonnage préférentiel

## Avantages

- ▶ Très utile pour l'estimation de quantités petites (probabilités d'évènements rares).
- ▶ Peut amener à une forte réduction de variance
- ▶ Peut aussi être utilisé quand on ne sait pas simuler selon  $f$ !

## Attention!

- ▶ Nécessite le choix de  $g$ ! Pas toujours évident (notamment en grande dimension)!
- ▶ Un mauvais  $g$  peut amener à un estimateur de variance infinie! (voir TD).
- ▶ Un bon choix de  $g$  est souvent “problème dépendant”, (ne conviendra que pour  $\mathbb{E}[\varphi(X)]$  pour un  $\varphi$  spécifique).

## Echantillonnage préférentiel normalisé

# Problématique

Objectif, calculer:

$$I = \mathbb{E}[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x) f(x) d(x)$$

Supposons que  $f$  ne soit connue qu'à une constante près:

$$f(x) = \frac{\overbrace{f^{(u)}(x)}^{\text{Connu}}}{\underbrace{\int_{\mathcal{D}_f} f^{(u)}(z) dz}_{\text{Inconnu}}}.$$

- ▶ Pour une densité de proposition  $g$ , on ne peut plus calculer le poids d'importance!

# Problématique

Objectif, calculer:

$$I = \mathbb{E}[\varphi(X)] = \int_{\mathcal{D}_f} \varphi(x) f(x) d(x)$$

Supposons que  $f$  ne soit connue qu'à une constante près:

$$f(x) = \frac{\overbrace{f^{(u)}(x)}^{\text{Connu}}}{\underbrace{\int_{\mathcal{D}_f} f^{(u)}(z) dz}_{\text{Inconnu}}}.$$

- ▶ Pour une densité de proposition  $g$ , on ne peut plus calculer le poids d'importance!
- ▶ Ce cas est en pratique très fréquent en inférence bayésienne!

## Echantillonnage préférentiel normalisé

Si on dispose d'une loi de proposition  $g$  et de  $Y_1, \dots, Y_M$  tirés indépendamment selon  $g$ , alors l'estimateur:

$$\hat{I}_M^{IS,u} = \sum_{k=1}^M \frac{f^{(u)}(Y_k)/g(Y_k)}{\sum_{\ell=1}^M f^{(u)}(Y_\ell)/g(Y_\ell)} \varphi(Y_k)$$

est un estimateur consistant (convergence en proba.) de  $I$ .

## Echantillonnage préférentiel normalisé

Si on dispose d'une loi de proposition  $g$  et de  $Y_1, \dots, Y_M$  tirés indépendamment selon  $g$ , alors l'estimateur:

$$\hat{I}_M^{IS,u} = \sum_{k=1}^M \frac{f^{(u)}(Y_k)/g(Y_k)}{\sum_{\ell=1}^M f^{(u)}(Y_\ell)/g(Y_\ell)} \varphi(Y_k)$$

est un estimateur consistant (convergence en proba.) de  $I$ .

- ▶ Estimateur biaisé pour  $M$  petit;
- ▶ Peut amener à un estimateur de variance plus faible que l'échantillonnage préférentiel classique.

## Autres méthodes de réduction de variance

- ▶ Conditionnement
- ▶ Variables de contrôles
- ▶ Quasi Monte Carlo

Voir références dans le poly.

# Simulations de variables aléatoires

Pierre Gloaguen

07/04/2020

## Années:

- ▶ Premier rendu pour le 13 Avril à midi (exo5 du TD1)
- ▶ À faire en binome et à rendre sur Ecampus
- ▶ TD sur échantillonnage préférentiel en ligne sur ma page.
- ▶ Rendre l'exo 3 pour le 21 Avril au soir.

## Rappel des précédents

- ▶ Nécessité en statistiques d'évaluer des espérances;
- ▶ Principes des méthodes de Monte Carlo:
  - ▶ Classiques et échantillonnage préférentiel.
- ▶ Approximation d'intégrales (espérances) par simulation de variables aléatoires.
- ▶ Fonctionne grâce à la loi des grands nombres, IC grâce au TCL.

## Rappel des précédents

- ▶ Nécessité en statistiques d'évaluer des espérances;
- ▶ Principes des méthodes de Monte Carlo:
  - ▶ Classiques et échantillonnage préférentiel.
- ▶ Approximation d'intégrales (espérances) par simulation de variables aléatoires.
- ▶ Fonctionne grâce à la loi des grands nombres, IC grâce au TCL.
- ▶ Comment simule t'on ces lois?
  - ▶ Lois usuelles implémentées dans R (ou autre...)
  - ▶ Comment est ce fait?
  - ▶ Pour des lois non usuelles, comment faire?

# Objectif du cours

- ▶ Comment simuler une loi uniforme continue avec un ordinateur?
  - ▶ Générateurs pseudo aléatoires;
- ▶ Comment simuler des lois génériques à partir de lois uniformes?
  - ▶ Méthode d'inversion;
- ▶ Comment simuler des lois non classique à partir de lois simulables?
  - ▶ Méthode d'acceptation rejet.

## Générateurs pseudo aléatoires

# Simulation de variables aléatoires par ordinateur

**Objectif:** Simuler une suite de variables aléatoires  $X_1, \dots, X_M$  telles qu'elles soient:

- ▶ Distribuées selon une même loi donnée:
- ▶ Mutuellement indépendantes.

# Simulation de variables aléatoires par ordinateur

**Objectif:** Simuler une suite de variables aléatoires  $X_1, \dots, X_M$  telles qu'elles soient:

- ▶ Distribuées selon une même loi donnée;
- ▶ Mutuellement indépendantes.
- ▶ Une telle simulation est faite selon un algorithme **déterministe**;

# Simulation de variables aléatoires par ordinateur

**Objectif:** Simuler une suite de variables aléatoires  $X_1, \dots, X_M$  telles qu'elles soient:

- ▶ Distribuées selon une même loi donnée;
- ▶ Mutuellement indépendantes.
- ▶ Une telle simulation est faite selon un algorithme **déterministe**;
- ▶ À l'heure actuelle, un ordinateur ne peut que **mimer l'aléa**;

# Simulation de variables aléatoires par ordinateur

**Objectif:** Simuler une suite de variables aléatoires  $X_1, \dots, X_M$  telles qu'elles soient:

- ▶ Distribuées selon une même loi donnée;
- ▶ Mutuellement indépendantes.
- ▶ Une telle simulation est faite selon un algorithme **déterministe**;
- ▶ À l'heure actuelle, un ordinateur ne peut que **mimer l'aléa**;
- ▶ **Mimer l'aléa:** Pour un échantillon de loi donnée:
  - ▶ Passer les tests statistiques usuels d'adéquations (test du  $\chi^2$ , test de Kolmogorov Smirnoff);
  - ▶ Passer les tests d'indépendances usuels (test du  $\chi^2$ , test de corrélation linéaire, ...).

## Générateur de la loi uniforme $\mathcal{U}[0, 1]$

- ▶ En pratique, la loi “atomique” est la loi  $\mathcal{U}[0, 1]$ ;

## Générateur de la loi uniforme $\mathcal{U}[0, 1]$

- ▶ En pratique, la loi “atomique” est la loi  $\mathcal{U}[0, 1]$ ;
- ▶ Si on sait simuler selon cette loi, par différentes méthodes on pourra se ramener aux autres.

## Générateur de la loi uniforme $\mathcal{U}[0, 1]$

- ▶ En pratique, la loi “atomique” est la loi  $\mathcal{U}[0, 1]$ ;
- ▶ Si on sait simuler selon cette loi, par différentes méthodes on pourra se ramener aux autres.
- ▶ Nécessité d'un algorithme permettant de mimer un échantillon i.i.d. de loi  $\mathcal{U}[0, 1]$ .

## Algorithme de congruence linéaire

Algorithme basé sur 4 données initiales choisies par l'utilisateur:

- ▶ Un entier  $m > 0$ , appelé *module*;
- ▶ Un entier  $0 < a < m$  appelé *multiplicateur*;
- ▶ Un entier  $0 \leq c < m$  appelé *incrément*;
- ▶ Un entier  $0 \leq x_0 < m$  appelé *graine*.

## Algorithme de congruence linéaire

Algorithme basé sur 4 données initiales choisies par l'utilisateur:

- ▶ Un entier  $m > 0$ , appelé *module*;
- ▶ Un entier  $0 < a < m$  appelé *multiplicateur*;
- ▶ Un entier  $0 \leq c < m$  appelé *incrément*;
- ▶ Un entier  $0 \leq x_0 < m$  appelé *graine*.

On créera alors une suite de nombres  $x_1, \dots, x_n$  en utilisant la relation de récurrence

$$x_k = (ax_{k-1} + c) \text{ modulo } m.$$

## Algorithme de congruence linéaire

Algorithme basé sur 4 données initiales choisies par l'utilisateur:

- ▶ Un entier  $m > 0$ , appelé *module*;
- ▶ Un entier  $0 < a < m$  appelé *multiplicateur*;
- ▶ Un entier  $0 \leq c < m$  appelé *incrément*;
- ▶ Un entier  $0 \leq x_0 < m$  appelé *graine*.

On créera alors une suite de nombres  $x_1, \dots, x_n$  en utilisant la relation de récurrence

$$x_k = (ax_{k-1} + c) \text{ modulo } m.$$

On définit enfin les nombres  $u_1, \dots, u_n$  dans l'intervalle  $[0, 1]$ :

$$u_k = \frac{x_k}{m}, \quad 1 \leq k \leq n.$$

## Algorithme de congruence linéaire

```
mon_runif <- function(n , a, m, c, x0){  
    echantillon <- rep(NA, n + 1)  
    # %% est l'opérateur modulo  
    x_vals[1] <- (x0 %% m) # Initialisation  
    for(k in 2:(n + 1)){ # Iteration  
        x_vals[k] <- (a * x_vals[k - 1] + c) %% m  
    }  
    u_vals <- x_vals / m # Mise entre 0 et 1  
    return(u_vals[-1])  
    # On ne retourne pas la graine  
}
```

## Choix de a, m, c, x0

- ▶ À  $x_0$  fixé, la séquence obtenue est **toujours la même.**
  - ▶ En pratique, elle n'est pas demandée à l'utilisateur, mais obtenue en interne.
  - ▶ Exemple: nombre de millisecondes (modulo  $m$ ) écoulé depuis le 1er Janvier 1970.

## Choix de a, m, c, x0

- ▶ À  $x_0$  fixé, la séquence obtenue est **toujours la même.**
  - ▶ En pratique, elle n'est pas demandée à l'utilisateur, mais obtenue en interne.
  - ▶ Exemple: nombre de millisecondes (modulo  $m$ ) écoulé depuis le 1er Janvier 1970.
- ▶ Doit couvrir "tout"  $[0, 1]$ :
  - ▶  $\Rightarrow m$  grand;

## Choix de a, m, c, x0


- ▶ À  $x_0$  fixé, la séquence obtenue est **toujours la même.**
  - ▶ En pratique, elle n'est pas demandée à l'utilisateur, mais obtenue en interne.
  - ▶ Exemple: nombre de millisecondes (modulo  $m$ ) écoulé depuis le 1er Janvier 1970.
- ▶ Doit couvrir "tout"  $[0, 1]$ :
  - ▶  $\Rightarrow m$  grand;
- ▶ La suite est nécessairement **périodique!**
  - ▶ On veut une période "invisible" (mimer l'indépendance);
  - ▶  $\Rightarrow a$  grand **et** relativement premier à  $m$ .

## Choix de a, m, c, x0

- ▶ À  $x_0$  fixé, la séquence obtenue est **toujours la même.**
  - ▶ En pratique, elle n'est pas demandée à l'utilisateur, mais obtenue en interne.
  - ▶ Exemple: nombre de millisecondes (modulo  $m$ ) écoulé depuis le 1er Janvier 1970.
- ▶ Doit couvrir "tout"  $[0, 1]$ :
  - ▶  $\Rightarrow m$  grand;
- ▶ La suite est nécessairement **périodique!**
  - ▶ On veut une période "invisible" (mimer l'indépendance);
  - ▶  $\Rightarrow a$  grand **et** relativement premier à  $m$ .
- ▶ Considération algorithmiques sur le modulo.
- ▶ Voir références poly.

## Choix important (distribution)

3 jeux de paramètres (voir TD), donnant 3 suites de 10000 valeurs entre 0 et 1




Au risque 5%, avec un test de Kolmogorov-Smirnoff, on rejette

- ▶  $H_0$  : Echantillon de loi uniforme  $\mathcal{U}[0, 1]$   
seulement pour l'échantillon 3.

## Choix important (indépendance)

On regarde, pour les 3 échantillons, la valeur de  $u_k$  en fonction de celle de  $u_{k-1}$ :



Il y a une forte autocorrélation empirique dans les deux derniers échantillons!

## Loi uniforme générique

- ▶ Si on sait simuler  $U \sim \mathcal{U}[0, 1]$ , alors, pour  $a < b \in \mathbb{R}$

$$(b - a)U + a \sim \mathcal{U}[a, b]$$

- ▶ Dans R, la simulation d'une loi uniforme est faite avec `runif`;
- ▶ Dans la suite: on suppose qu'on sait simuler selon  $\mathcal{U}[0, 1]$ .

## Méthode d'inversion

## Rappel: Fonction de répartition

Soit  $X$  une variable aléatoire à valeurs réelles. Pour tout réel  $x$ , on appelle fonction de répartition de  $X$  la fonction  $F_X$ :

$$\begin{aligned}\mathbb{R} &\mapsto [0, 1] \\ x &\mapsto F_X(x) = \mathbb{P}(X \leq x)\end{aligned}$$

## Rappel: Fonction de répartition

Soit  $X$  une variable aléatoire à valeurs réelles. Pour tout réel  $x$ , on appelle fonction de répartition de  $X$  la fonction  $F_X$ :

$$\begin{aligned}\mathbb{R} &\mapsto [0, 1] \\ x &\mapsto F_X(x) = \mathbb{P}(X \leq x)\end{aligned}$$

Une fonction de répartition  $F_X$  est caractérisée par les propriétés suivantes:

1.  $F_X$  est partout continue à droite, i.e. pour tout  $x \in \mathbb{R}$ :

$$\lim_{\substack{h \rightarrow 0 \\ > 0}} F(x + h) = F(x)$$

2.  $F_X$  est croissante.
3.  $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow +\infty} F_X(x) = 1$

Ainsi, toute fonction  $F$  sur  $\mathbb{R}$  satisfaisant ces conditions est une fonction de répartition.

## Exemple: Fonction de répartition






Figure 1: Exemples de fonctions de répartition pour une variable aléatoire discrète (haut), continue (centre) ou avec atome (bas). Source [Wikipedia](#).

## Inverse généralisée de $F$ (fonction quantile)

Soit  $F$  une fonction de répartition, on appelle inverse généralisée de  $F$ , notée,  $F^{-1}$  la fonction:

$$\begin{aligned} ]0, 1[ &\mapsto \mathbb{R} \\ u &\mapsto F^{-1}(u) = \inf \{z \in \mathbb{R} \text{ tel que } F(z) \geq u\} \end{aligned}$$

Pour une variable aléatoire  $X$ , la fonction  $F_X^{-1}$  est également appelée *fonction quantile* de la variable aléatoire  $X$ . On convient que  $F_X^{-1}(0)$  et  $F_X^{-1}(1)$  sont la plus petite et la plus grande des valeurs du support de  $X$  (éventuellement infinies).

## Inverse généralisée

**Remarque:** Dans le cas d'une fonction de répartition  $F$  continue et strictement croissante sur  $\mathbb{R}$ , la fonction  $F^{-1}$  est simplement l'inverse de  $F$ .

## Méthode d'inversion

Supposons qu'on ait une variable aléatoire  $X$  dont on connaît la fonction de répartition  $F$ , comment simuler  $X$ ?

## Méthode d'inversion

Supposons qu'on ait une variable aléatoire  $X$  dont on connaît la fonction de répartition  $F$ , comment simuler  $X$ ?

*Exemple:*  $X \sim \text{Exp}(\lambda)$ :

- ▶ **Densité:**  $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{x \geq 0}$

## Méthode d'inversion

Supposons qu'on ait une variable aléatoire  $X$  dont on connaît la fonction de répartition  $F$ , comment simuler  $X$ ?

*Exemple:*  $X \sim \text{Exp}(\lambda)$ :

► **Densité:**  $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{x \geq 0}$

► **Fonction de répartition:**

$$F(x) = \int_{-\infty}^x f(z) dz = (1 - e^{-\lambda x}) \mathbf{1}_{x \geq 0}$$

## Méthode d'inversion

Supposons qu'on ait une variable aléatoire  $X$  dont on connaît la fonction de répartition  $F$ , comment simuler  $X$ ?

*Exemple:*  $X \sim \text{Exp}(\lambda)$ :

- ▶ **Densité:**  $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{x \geq 0}$
- ▶ **Fonction de répartition:**  
$$F(x) = \int_{-\infty}^x f(z) dz = (1 - e^{-\lambda x}) \mathbf{1}_{x \geq 0}$$
- ▶ **Inverse généralisée:**  $0 < u < 1, F^{-1}(u) = -\frac{\ln(1-u)}{\lambda}$

## Méthode d'inversion

Supposons qu'on ait une variable aléatoire  $X$  dont on connaît la fonction de répartition  $F$ , comment simuler  $X$ ?

*Exemple:*  $X \sim \text{Exp}(\lambda)$ :

- ▶ **Densité:**  $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{x \geq 0}$
- ▶ **Fonction de répartition:**  
$$F(x) = \int_{-\infty}^x f(z) dz = (1 - e^{-\lambda x}) \mathbf{1}_{x \geq 0}$$
- ▶ **Inverse généralisée:**  $0 < u < 1, F^{-1}(u) = -\frac{\ln(1-u)}{\lambda}$

**Méthode d'inversion** Soit  $F$  une fonction de répartition. Soit  $F^{-1}$  son inverse généralisée. Soit  $U$  une variable aléatoire de loi uniforme sur  $[0, 1]$ , alors la variable aléatoire

$$X := F^{-1}(U)$$

admet  $F$  comme fonction de répartition.

## Exemple de méthode d'inversion


$$F^{-1}(u) = -\frac{\ln(1-u)}{\lambda}$$

```
mon_rexp <- function(n, lambda){  
  # On simule selon une loi uniforme  
  us <- runif(n) # Echantillon IID U[0,1]  
  # On applique la fonction quantile a l'échantillon  
  - log(1 - us) / lambda  
}
```

## Exemple de méthode d'inversion

$$F^{-1}(u) = -\frac{\ln(1-u)}{\lambda}$$

Echantillon de taille 10000,  $\lambda = 1$



## Preuve de la méthode d'inversion

On veut montrer que, pour tout  $x \in \mathbb{R}$ , si  $U \sim \mathcal{U}[0, 1]$ , alors

$$\mathbb{P}(F^{-1}(U) \leq x) = F(x).$$

## Preuve de la méthode d'inversion

On veut montrer que, pour tout  $x \in \mathbb{R}$ , si  $U \sim \mathcal{U}[0, 1]$ , alors

$$\mathbb{P}(F^{-1}(U) \leq x) = F(x).$$

Montrons tout d'abord que, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Leftrightarrow u \leq F(x). \quad (1)$$

## Preuve de la méthode d'inversion

On veut montrer que, pour tout  $x \in \mathbb{R}$ , si  $U \sim \mathcal{U}[0, 1]$ , alors

$$\mathbb{P}(F^{-1}(U) \leq x) = F(x).$$

Montrons tout d'abord que, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Leftrightarrow u \leq F(x). \quad (1)$$

En effet, si on y parvient, il restera à conclure en se servant de la définition d'une loi uniforme:

$$\mathbb{P}(F^{-1}(U) \leq x) \stackrel{\text{par (1)}}{=} \mathbb{P}(U \leq F(x)) \stackrel{\text{car } U \sim \mathcal{U}[0, 1]}{=} F(x).$$

## Preuve de la méthode d'inversion

Montrons d'abord que, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Rightarrow u \leq F(x).$$

## Preuve de la méthode d'inversion

Montrons d'abord que, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Rightarrow u \leq F(x).$$

⇒ Soient  $u \in ]0, 1[$  et  $x \in \mathbb{R}$  tels que  $F^{-1}(u) \leq x$ .

Par croissance de  $F$ , on a donc:

$$F(F^{-1}(u)) \leq F(x)$$

Or, en se souvenant que par définition

$$F^{-1}(u) = \inf \{z \in \mathbb{R} \text{ tel que } F(z) \geq u\},$$

on a donc directement

$$u \leq F(F^{-1}(u)) \leq F(x)$$

## Preuve de la méthode d'inversion

Montrons maintenant, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Leftarrow u \leq F(x).$$

## Preuve de la méthode d'inversion

Montrons maintenant, pour tout  $u \in ]0, 1[$

$$\forall x \in \mathbb{R}, F^{-1}(u) \leq x \Leftarrow u \leq F(x).$$

- $\Leftarrow$  Soient  $u \in ]0, 1[$  et  $x \in \mathbb{R}$  tels que  $u \leq F(x)$ .  
Ainsi,  $x \in \{z \in \mathbb{R} \text{ tel que } F(z) \geq u\}$ , donc  $F^{-1}(u) \leq x$ .

## Intérêt de la méthode d'inversion

Ainsi, pour une variable aléatoire à valeurs dans  $\mathbb{R}$ , on sait simuler si on connaît l'inverse généralisée de sa fonction de répartition.

## Méthode d'acceptation rejet

## Exemple motivant

On veut simuler selon la densité  $f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \mathbf{1}_{x \geq 0}$ .

La fonction quantile n'a pas d'expression analytique. La méthode d'inversion ne peut être appliquée.

## Exemple motivant

On veut simuler selon la densité  $f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \mathbf{1}_{x \geq 0}$ .

La fonction quantile n'a pas d'expression analytique. La méthode d'inversion ne peut être appliquée.

### **Principe de la méthode d'acceptation rejet:**

- ▶ Simuler des *candidats* selon une autre loi qu'on sait simuler.

## Exemple motivant

On veut simuler selon la densité  $f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \mathbf{1}_{x \geq 0}$ .

La fonction quantile n'a pas d'expression analytique. La méthode d'inversion ne peut être appliquée.

### Principe de la méthode d'acceptation rejet:

- ▶ Simuler des *candidats* selon une autre loi qu'on sait simuler.
- ▶ Choisir parmi les candidats grâce à la loi uniforme.

## Méthode d'acceptation rejet (proposition)

Soit  $f$  et  $g$  deux densités sur  $\mathbb{R}^d$ . On suppose qu'il existe une constante  $M$  telle que

$$\forall x \in \mathbb{R}^d \quad f(x) \leq Mg(x)$$

On note

$$0 \leq r(x) := \frac{f(x)}{Mg(x)} \leq 1.$$

## Méthode d'acceptation rejet (proposition)

Soit  $f$  et  $g$  deux densités sur  $\mathbb{R}^d$ . On suppose qu'il existe une constante  $M$  telle que

$$\forall x \in \mathbb{R}^d \quad f(x) \leq Mg(x)$$

On note

$$0 \leq r(x) := \frac{f(x)}{Mg(x)} \leq 1.$$

- Soient  $(Y_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de densité  $g$  et  $(U_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de loi uniforme sur  $[0, 1]$ .

## Méthode d'acceptation rejet (proposition)

Soit  $f$  et  $g$  deux densités sur  $\mathbb{R}^d$ . On suppose qu'il existe une constante  $M$  telle que

$$\forall x \in \mathbb{R}^d \quad f(x) \leq Mg(x)$$

On note

$$0 \leq r(x) := \frac{f(x)}{Mg(x)} \leq 1.$$

- Soient  $(Y_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de densité  $g$  et  $(U_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de loi uniforme sur  $[0, 1]$ . - On note  $T$  la variable aléatoire (à valeurs dans  $\mathbb{N}^*$ ):

$$T = \inf \{n, \text{ tel que } U_n \leq r(Y_n)\}.$$

## Méthode d'acceptation rejet (proposition)

Soit  $f$  et  $g$  deux densités sur  $\mathbb{R}^d$ . On suppose qu'il existe une constante  $M$  telle que

$$\forall x \in \mathbb{R}^d \quad f(x) \leq Mg(x)$$

On note

$$0 \leq r(x) := \frac{f(x)}{Mg(x)} \leq 1.$$

- Soient  $(Y_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de densité  $g$  et  $(U_n)_{n \geq 1}$  une suite de variables aléatoires i.i.d. de loi uniforme sur  $[0, 1]$ . - On note  $T$  la variable aléatoire (à valeurs dans  $\mathbb{N}^*$ ):

$$T = \inf \{n, \text{ tel que } U_n \leq r(Y_n)\}.$$

. - Alors, la variable aléatoire  $X := Y_T$  ( $T$ -ième valeur de la suite  $(Y_n)_{n \geq 1}$ ) a pour densité  $f$ .

## Méthode d'acceptation rejet (algorithme)

On veut tirer un échantillon  $X$  de densité  $f$ . On ne sait simuler que selon la densité  $g$ . On suppose qu'il existe une constante  $M$  telle que

$$\forall x \in \mathbb{R}^d \quad f(x) \leq Mg(x)$$

**Algorithme** Condition  $\leftarrow$  FALSE

► Tant que not Condition:

- Tirer  $Y \sim g(y)$ ;
- Tirer (indépendamment)  $U \sim \mathcal{U}[0, 1]$ ;
- Si

$$U \leq \frac{f(Y)}{Mg(Y)},$$

alors on pose Condition  $\leftarrow$  TRUE et  $X = Y$


- Sinon Condition  $\leftarrow$  FALSE

En sortie,  $X \sim f(x)$ .

## Méthode d'acceptation rejet: Exemple


- ▶ On veut simuler selon  $f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \mathbf{1}_{x \geq 0}$
- ▶ On considère  $g(x) = e^{-x} \mathbf{1}_{x \geq 0}$  (densité d'un  $\mathcal{Exp}(\lambda = 1)$ )
- ▶ On montre que

$$\forall x \in \mathbb{R}, f(x) \leq \underbrace{\sqrt{\frac{2}{\pi}} e^{\frac{1}{2}}}_{M} g(x)$$




## Méthode d'acceptation rejet: Exemple

- ▶ On simule 10000 points selon  $g$




## Méthode d'acceptation rejet: Exemple

- ▶ On simule 10000 points selon  $g$
- ▶ On accepte avec une probabilité donnée par le ratio



## Méthode d'acceptation rejet: Exemple

- ▶ On simule 10000 points selon  $g$
- ▶ On accepte avec une probabilité donnée par le ratio
- ▶ Les points acceptés sont i.i.d. de densité  $f$ .



## Remarque

Sur l'exemple précédent, au lieu de faire un “tant que”, on a simuler 10000 points et on n'a retenu que les acceptés.

## Remarque

Sur l'exemple précédent, au lieu de faire un "tant que", on a simuler 10000 points et on n'a retenu que les acceptés.

- ▶ Proportion empirique acceptée: 0.761
- ▶ D'un autre côté, on a  $1/M = 0.76$

## Preuve de la méthode d'acceptation rejet

Preuve à connaître!

- ▶ Voir le poly de cours.
- ▶ Analogue de la preuve sera demandée en devoir.


## Code R

```
get_one_sample <- function(){
  condition <- FALSE
  while(!condition){
    y <- simulate_g(...) # Simulation selon g
    u <- runif(1) # Uniform
    # On suppose que f, g, et M existent
    condition <- u <= f(y) / (M * g(y))
  }
  return(y)
}
```

## Loi du temps d'attente

On s'arrête au premier temps tel qu'une uniforme est inférieure au ratio observée.

La loi du temps d'attente (voir preuve) est une **loi géométrique** sur  $\mathbb{N}^*$  de paramètre  $\frac{1}{M}$ .



## Vecteurs aléatoires

Pour simuler un vecteur aléatoire  $(X, Y)$ , on pourra utiliser (voir poly et TD pour des exemples):

- ▶ Conditionnement;
- ▶ Changement de variables

## Changements de variables pour densité

Soit un couple de variables aléatoires  $(U, V)$  de densité  $f_{U,V}(u, v)$  définie sur  $E_{UV} \subset \mathbb{R}^2$  et un couple de variables aléatoires  $(X, Y)$  à valeurs dans  $E_{XY} \subset \mathbb{R}^2$ . Supposons qu'il existe une application  $\phi$ ,  $C^1$ , inversible, et d'inverse  $C^1$ , tel que  $(X, Y) = \phi(U, V)$ , alors la densité jointe de  $(X, Y)$  est donnée par:

$$f_{X,Y}(x, y) = f_{U,V}(\phi^{-1}(x, y)) |\det J_{\phi^{-1}}(x, y)|$$

où  $J_\phi$  désigne la matrice jacobienne d'une application  $\phi(u, v)$ :

$$J_\phi(u, v) = \begin{pmatrix} \frac{\delta \phi_1}{\delta u}(u, v) & \frac{\delta \phi_1}{\delta v}(u, v) \\ \frac{\delta \phi_2}{\delta u}(u, v) & \frac{\delta \phi_2}{\delta v}(u, v) \end{pmatrix}$$

# Introduction à l'inférence bayesienne

Pierre Gloaguen

Avril 2020

## Rappel des cours précédents

- ▶ Méthodes de Monte Carlo pour le calcul d'intégrales
- ▶ Echantillonnage préférentiel
- ▶ Méthodes de simulations de variables aléatoires

## Rappel des cours précédents

- ▶ Méthodes de Monte Carlo pour le calcul d'intégrales
- ▶ Echantillonnage préférentiel
- ▶ Méthodes de simulations de variables aléatoires
- ▶ Intérêt statistique?
  - ▶ Permet l'approximation de probabilité (prise de décision)
  - ▶ Point clé de l'inférence bayésienne

## Objectifs du cours

- ▶ Présentation du principe de l'inférence bayésienne;
- ▶ Deux exemples illustratifs;
- ▶ Définition des notions clés;

## Objectifs du cours

- ▶ Présentation du principe de l'inférence bayésienne;
- ▶ Deux exemples illustratifs;
- ▶ Définition des notions clés;
- ▶ Lien avec le maximum de vraisemblance;
- ▶ Lien avec les premiers chapitres du cours;

## Exemple introductif

## Simple modèle paramétrique

### Expérience et question

Supposons que l'on observe  $n = 10$  tirages indépendant de pile ou face. On compte 8 observations de pile et 2 de face.

Quelle est la probabilité que la pièce tombe sur pile?

### Modélisation

On note  $x_1, \dots, x_{10}$  le résultat du lancer (0 si *face*, 1 si *pile*). On suppose que ces nombres sont les réalisations de 10 V.A.  $X_1, \dots, X_{10}$  i.i.d. de loi  $Bern(\theta)$  où  $\theta \in ]0, 1[$  est la probabilité d'obtenir pile.

Donc, la loi jointe de  $\mathbf{X} = (X_1, \dots, X_n)$  est donnée par:

$$L(x_1, \dots, x_n | \theta) = \prod_{k=1}^n \mathbb{P}_\theta(X = x_k) = \theta^{\sum_{k=1}^n x_k} (1 - \theta)^{n - \sum_{k=1}^n x_k}$$

où  $X \sim Bern(\theta)$ .

## Inférence par maximum de vraisemblance

Pour un échantillon  $\mathbf{X} = X_1, \dots, X_n$ , et pour un paramètre  $\theta \in ]0, 1[$ , la *vraisemblance* de  $\theta$  est:

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X = x_k) = \theta^{\sum_{k=1}^n x_k} (1 - \theta)^{n - \sum_{k=1}^n x_k}$$

## Inférence par maximum de vraisemblance

Pour un échantillon  $\mathbf{X} = X_1, \dots, X_n$ , et pour un paramètre  $\theta \in ]0, 1[$ , la *vraisemblance* de  $\theta$  est:

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X = x_k) = \theta^{\sum_{k=1}^n x_k} (1 - \theta)^{n - \sum_{k=1}^n x_k}$$

### Maximum de vraisemblance

L'estimateur du maximum de vraisemblance pour  $x_{1:n}$  est donné par


$$\hat{\theta} = \operatorname{argmax}_\theta L(x_{1:n}|\theta) = \frac{\sum_{i=1}^n x_i}{n}.$$

L'estimateur est **entièrement basé sur les données**.


### Incertitude sur $\hat{\theta}$

$\hat{\theta}$  est une variable aléatoire. La théorie du MLE nous dit que cet estimateur admet un TCL. Ainsi, *asymptotiquement*, on a toujours un intervalle de confiance pour  $\theta$ . Cet IC est aléatoire (mais pas  $\theta!$ ).

## Vraisemblance pour $n = 10$ et 8 succès



## Vraisemblance pour $n = 1000$ et 800 succès



## Inférence bayésienne

### A priori sur $\theta$

- ▶ On a potentiellement une connaissance *a priori* sur  $\theta$ .

### A priori sur $\theta$

- ▶ On a potentiellement une connaissance *a priori* sur  $\theta$ .
- ▶ On peut modéliser cet *a priori* sur le paramètre  $\theta$  (savoir expert...) par une **variable aléatoire** de densité  $\pi(\theta)$ .

## A priori sur $\theta$


- ▶ On a potentiellement une connaissance *a priori* sur  $\theta$ .
- ▶ On peut modéliser cet *a priori* sur le paramètre  $\theta$  (savoir expert...) par une **variable aléatoire** de densité  $\pi(\theta)$ .
- ▶ Cette distribution est appelée **prior** sur  $\theta$ .

### A priori sur $\theta$

- ▶ On a potentiellement une connaissance *a priori* sur  $\theta$ .
- ▶ On peut modéliser cet *a priori* sur le paramètre  $\theta$  (savoir expert...) par une **variable aléatoire** de densité  $\pi(\theta)$ .
- ▶ Cette distribution est appelée **prior** sur  $\theta$ .
- ▶ Dans ce contexte,  $\theta$  est un variable aléatoire, on dispose d'un *a priori* sur sa loi.

## Exemples de loi a priori


Aucune idée sur  $\theta$



**Remarque** une loi  $\mathcal{U}[0, 1]$  est **strictement** équivalente à une loi  $Beta(1, 1)$ .


## Exemples de loi a priori

A priori léger sur une pièce équitable



## Exemples de loi a priori

A priori fort sur une pièce inéquitable



## Inférence bayésienne

## Inférence bayésienne



*Une formule magique ! S'appliquant à n'importe quel phénomène, elle produit des résultats, livre des découvertes, établit des vérités. Mieux : des neurologues y voient la clé de notre façon de penser ! Pourtant, cette formule est simplissime et connue... depuis trois siècles. Oui, mais ce n'est qu'aujourd'hui qu'elle dévoile son incroyable puissance. Son nom ? La formule de Bayes.*

## Inférence bayésienne

### Influence des données, distribution a posteriori.

- ▶ L'objectif est de l'inférence est de **connaître la distribution de  $\theta$  sachant les données.**

## Inférence bayésienne

### Influence des données, distribution a posteriori.

- ▶ L'objectif est de l'inférence est de **connaître la distribution de  $\theta$  sachant les données.**
- ▶ La densité de cette distribution sur  $\theta$  est notée  $\pi(\theta|\mathbf{x})$ , et est appelée **posterior** ou **loi a posteriori**.

## Inférence bayésienne

### Influence des données, distribution a posteriori.

- ▶ L'objectif est de l'inférence est de **connaître la distribution de  $\theta$  sachant les données.**
- ▶ La densité de cette distribution sur  $\theta$  est notée  $\pi(\theta|\mathbf{x})$ , et est appelée **posterior ou loi a posteriori**.
- ▶ On **actualise** notre connaissance sur  $\theta$  grâce aux données.

## Inférence bayésienne

### Influence des données, distribution a posteriori.

- ▶ L'objectif est de l'inférence est de **connaître la distribution de  $\theta$  sachant les données**.
- ▶ La densité de cette distribution sur  $\theta$  est notée  $\pi(\theta|\mathbf{x})$ , et est appelée **posterior ou loi a posteriori**.
- ▶ On **actualise** notre connaissance sur  $\theta$  grâce aux données.

### Formule de Bayes

$$\mathbb{P}(B|A) = \frac{P(A|B)\mathbb{P}(B)}{\mathbb{P}(A)}$$

## Inférence bayésienne

### Influence des données, distribution a posteriori.

- ▶ L'objectif est de l'inférence est de **connaître la distribution de  $\theta$  sachant les données.**
- ▶ La densité de cette distribution sur  $\theta$  est notée  $\pi(\theta|\mathbf{x})$ , et est appelée **posterior ou loi a posteriori**.
- ▶ On **actualise** notre connaissance sur  $\theta$  grâce aux données.

### Formule de Bayes

$$\mathbb{P}(B|A) = \frac{P(A|B)\mathbb{P}(B)}{\mathbb{P}(A)}$$

Dans le cas avec des densités:

$$\pi(\theta|x_{1:n}) = \frac{p(x_{1:n}, \theta)}{p(x_{1:n})} = \frac{L(x_{1:n}|\theta)\pi(\theta)}{p(x_{1:n})}$$

où  $p$  est notation surchargée pour les densités.

Cette relation est résumée par:

$$\pi(\theta|\mathbf{x}) \propto L(x_{1:n}|\theta)\pi(\theta)$$

## Objectif de l'inférence Bayésienne

$$\pi(\theta|\mathbf{x}) \propto L(x_{1:n}|\theta)\pi(\theta)$$

L'inférence Bayésienne a pour but la détermination (exacte, ou par simulation) du posterior  $\pi(\theta|\mathbf{x})$ .

Exemple 1: modèle avec prior conjugué

## Posterior dans le modèle Beta-Binomial

On revient au cas de pile ou on face où

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X = x_k) = \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n - \sum_{k=1}^n x_k}$$

## Posterior dans le modèle Beta-Binomial

On revient au cas de pile ou on face où

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X=x_k) = \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n-\sum_{k=1}^n x_k}$$

Pour l'inférence bayésienne, on pose comme *a priori* que  $\theta \sim \text{Beta}(a, b)$ , ainsi:

$$\pi(\theta) = \frac{\theta^{a-1} (1-\theta)^{b-1}}{\int_0^1 u^{a-1} (1-u)^{b-1} du} \mathbf{1}_{0 < \theta < 1} \propto \theta^{a-1} (1-\theta)^{b-1} \mathbf{1}_{0 < \theta < 1}$$

On cherche la loi de  $\theta|x_{1:n}$ .

## Posterior dans le modèle Beta-Binomial

On revient au cas de pile ou face où

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X=x_k) = \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n - \sum_{k=1}^n x_k}$$

Pour l'inférence bayésienne, on pose comme *a priori* que  $\theta \sim \text{Beta}(a, b)$ , ainsi:

$$\pi(\theta) = \frac{\theta^{a-1} (1-\theta)^{b-1}}{\int_0^1 u^{a-1} (1-u)^{b-1} du} \mathbf{1}_{0 < \theta < 1} \propto \theta^{a-1} (1-\theta)^{b-1} \mathbf{1}_{0 < \theta < 1}$$

On cherche la loi de  $\theta|x_{1:n}$ .

$$\begin{aligned} \pi(\theta|x_{1:n}) &\propto L(x_{1:n}|\theta)\pi(\theta) \\ &\propto \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n - \sum_{k=1}^n x_k} \theta^{a-1} (1-\theta)^{b-1} \mathbf{1}_{0 < \theta < 1} \\ &\propto \theta^{a+\sum_{k=1}^n x_k - 1} (1-\theta)^{b+n - \sum_{k=1}^n x_k - 1} \mathbf{1}_{0 < \theta < 1} \end{aligned}$$

## Posterior dans le modèle Beta-Binomial

On revient au cas de pile ou face où

$$L(x_{1:n}|\theta) = \prod_{k=1}^n \mathbb{P}_\theta(X=x_k) = \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n-\sum_{k=1}^n x_k}$$

Pour l'inférence bayésienne, on pose comme *a priori* que  $\theta \sim \text{Beta}(a, b)$ , ainsi:

$$\pi(\theta) = \frac{\theta^{a-1} (1-\theta)^{b-1}}{\int_0^1 u^{a-1} (1-u)^{b-1} du} \mathbf{1}_{0 < \theta < 1} \propto \theta^{a-1} (1-\theta)^{b-1} \mathbf{1}_{0 < \theta < 1}$$

On cherche la loi de  $\theta|x_{1:n}$ .


$$\begin{aligned} \pi(\theta|x_{1:n}) &\propto L(x_{1:n}|\theta)\pi(\theta) \\ &\propto \theta^{\sum_{k=1}^n x_k} (1-\theta)^{n-\sum_{k=1}^n x_k} \theta^{a-1} (1-\theta)^{b-1} \mathbf{1}_{0 < \theta < 1} \\ &\propto \theta^{a+\sum_{k=1}^n x_k - 1} (1-\theta)^{b+n-\sum_{k=1}^n x_k - 1} \mathbf{1}_{0 < \theta < 1} \end{aligned}$$

On reconnaît que  $\pi(\theta|x)$  est la densité d'une loi

$$\theta|x_{1:n} \sim \beta \left( a + \sum_{k=1}^n x_k, b + n - \sum_{k=1}^n x_k \right)$$


## Cas $n = 10$ et 8 succès

$$\theta|x_{1:n} \sim \beta \left( a + \sum_i^n x_i, b + n - \sum_i^n x_i \right)$$



## Cas $n = 1000$ et 800 succès

$$\theta|x_{1:n} \sim \beta \left( a + \sum_i^n x_i, b + n - \sum_i^n x_i \right)$$



## Prior conjugué

Pour les modèles basés sur une vraisemblance “classique”, certains priors ont des priorités de conjugaison. Pour un modèle Bayésien, on appelle prior conjugué un prior  $\pi(\theta)$  tel que le posterior  $\pi(x|\theta)$  est dans la même famille de loi que  $\pi(\theta)$ .

### Exemples

- ▶ Modèle Bernouilli-Beta;
- ▶ Modèle Gaussien (prior: Normal Inverse Gamma);
- ▶ Modèle à densités dans la famille exponentielle.

### Intérêt

L'inférence est directe!

## Choix de prior et estimateurs Bayésiens

## Influence et choix du prior

Pour un nombre de données limité, la **forme du prior** a un impact sur la forme du posterior.

## Influence et choix du prior

Pour un nombre de données limité, la **forme du prior** a un impact sur la forme du posterior.

### Choix du prior

La forme du prior peut être choisie en fonction du *savoir expert* (littérature existante, expériences passées).

**ATTENTION:** Le support du posterior sera toujours inclu dans le support du prior.

## Influence et choix du prior

Pour un nombre de données limité, la **forme du prior** a un impact sur la forme du posterior.

### Choix du prior

La forme du prior peut être choisie en fonction du *savoir expert* (littérature existante, expériences passées).

**ATTENTION:** Le support du posterior sera toujours inclus dans le support du prior.

Si le prior charge tout le support de manière égale, on dit qu'il est **non informatif**.

### Prior impropre

Si le support de  $\theta$  est sur  $\mathbb{R}$ , un prior non informatif est une "uniforme sur  $\mathbb{R}$ ".

Ceci n'est pas une loi.

## Influence et choix du prior

Pour un nombre de données limité, la **forme du prior** a un impact sur la forme du posterior.

### Choix du prior

La forme du prior peut être choisie en fonction du *savoir expert* (littérature existante, expériences passées).

**ATTENTION:** Le support du posterior sera toujours inclus dans le support du prior.

Si le prior charge tout le support de manière égale, on dit qu'il est **non informatif**.

### Prior impropre

Si le support de  $\theta$  est sur  $\mathbb{R}$ , un prior non informatif est une "uniforme sur  $\mathbb{R}$ ".

Ceci n'est pas une loi.

On peut cependant noter abusivement  $\pi(\theta) \propto 1$ . Dans ce cas, si  $\frac{L(x_{1:n}|\theta)}{\int L(x_{1:n}|\theta)d\theta}$

définit une loi de probabilité en  $\theta$ , alors le posterior  $\pi(\theta|x)$  est bien défini.

- Le prior est alors dit **impropre**.

## Choix du prior

Exemple de prior impropre.

On suppose que  $\mathbf{x}$  est issu d'un échantillon i.i.d. de taille  $n$ , de loi  $\mathcal{N}(\mu, 1)$  où  $\mu$  est inconnu. N'ayant aucune idée de la valeur de  $\mu$ , on prend un prior non informatif. On a alors:

$$\begin{aligned}\pi(\mu | \mathbf{x}_{1:n}) &\propto L(\mathbf{x}_{1:n} | \theta) \\ &\propto e^{-\frac{1}{2} \sum_{k=1}^n (x_k - \mu)^2} \\ &\propto e^{-\frac{1}{2}(n\mu^2 - 2\mu \sum_{k=1}^n x_k)} \\ &\propto e^{-\frac{n}{2}(\mu - \frac{1}{n} \sum_{k=1}^n x_k)^2}\end{aligned}$$

Ainsi,

$$\mu | \mathbf{x}_{1:n} \sim \mathcal{N}\left(\frac{1}{n} \sum_{k=1}^n x_k, \frac{1}{n}\right)$$

## Estimateurs Bayésiens

### Maximum a posteriori (MAP)

Retenant l'idée du MLE, il s'agit du mode de la distribution a posteriori:

$$MAP(\theta|x_{1:n}) = \operatorname{argmax}_{\theta} \pi(\theta|x_{1:n})$$

## Maximum a posteriori (MAP)

Retenant l'idée du MLE, il s'agit du mode de la distribution a posteriori:

$$MAP(\theta|x_{1:n}) = \operatorname{argmax}_{\theta} \pi(\theta|x_{1:n})$$

### Exemple sur la modèle Beta binomial

$$\theta|x_{1:n} \sim \beta \left( a + \sum_{k=1}^n x_k, b + n - \sum_{k=1}^n x_k \right)$$

On peut montrer que, pour  $a + b + n > 2$  et  $a + \sum_{k=1}^n x_k \geq 1$

$$MAP(\theta|x_{1:n}) = \frac{a + \sum_{k=1}^n x_k - 1}{a + b + n - 2}$$

## Maximum a posteriori (MAP)

Retenant l'idée du MLE, il s'agit du mode de la distribution a posteriori:

$$MAP(\theta|x_{1:n}) = \operatorname{argmax}_{\theta} \pi(\theta|x_{1:n})$$

### Exemple sur la modèle Beta binomial

$$\theta|x_{1:n} \sim \beta \left( a + \sum_{k=1}^n x_k, b + n - \sum_{k=1}^n x_k \right)$$

On peut montrer que, pour  $a + b + n > 2$  et  $a + \sum_{k=1}^n x_k \geq 1$

$$MAP(\theta|x_{1:n}) = \frac{a + \sum_{k=1}^n x_k - 1}{a + b + n - 2}$$

On remarque que pour  $a = b = 1$  (prior uniforme), il s'agit du maximum de vraisemblance, et que cela tend vers le MV quand  $n$  grandit.

## Estimateurs Bayésiens

### Espérance a posteriori

Soit un modèle Bayésien paramétré par une vraie valeur  $\theta^* \in \Theta$  et de prior  $\pi(\theta)$   
Pour toute fonction  $\varphi$ , la variable aléatoire

$$\mathbb{E}[\varphi(\theta)|\mathbf{X}]$$

est un estimateur Bayésien de  $\varphi(\theta^*)$ .

# Estimateurs Bayésiens

## Espérance a posteriori

Soit un modèle Bayésien paramétré par une vraie valeur  $\theta^* \in \Theta$  et de prior  $\pi(\theta)$   
Pour toute fonction  $\varphi$ , la variable aléatoire

$$\mathbb{E}[\varphi(\theta)|\mathbf{X}]$$

est un estimateur Bayésien de  $\varphi(\theta^*)$ .

Par exemple, pour un échantillon observé  $\mathbf{x}$ , une estimation bayésienne possible de  $\theta^*$  est

$$\hat{\theta} = \mathbb{E}[\theta|\mathbf{X} = \mathbf{x}_{1:n}] = \int_{\Theta} \theta \pi(\theta|\mathbf{x}_{1:n}) d\theta$$

## Exemple sur la modèle Beta-Binomial

Pour un prior  $\beta(a, b)$ , on a

$$\hat{\theta} \stackrel{\text{loi } \beta}{=} \frac{a + \sum_{i=1}^n x_i}{a + b + n} = \underbrace{\frac{n}{a + b + n}}_{\text{Poids données}} \times \overbrace{\frac{\sum_{i=1}^n x_i}{n}}^{\text{Max. de vrais.}} + \underbrace{\frac{a + b}{a + b + n}}_{\text{Poids prior}} \times \overbrace{\frac{a}{a + b}}^{\mathbb{E} \text{ du prior}}$$

## Estimateurs Bayésiens

### Intervalle de crédibilité

Pour toute région  $\mathcal{R} \subset \Theta$ , on peut quantifier:

$$\mathbb{P}(\theta \in \mathcal{R} | \mathbf{X} = x_{1:n}) = \int_{\mathcal{R}} \pi(\theta | x_{1:n}) d\theta$$


Pour  $\alpha \in ]0, 1[$ , une région de crédibilité de niveau  $1 - \alpha$  est une région  $\mathcal{R} \subset \Theta$  telle que

$$\mathbb{P}(\theta \in \mathcal{R} | \mathbf{X} = x_{1:n}) = 1 - \alpha$$

Cet intervalle n'est pas asymptotique, mais **dépend du prior**.

**Remarque**, ici l'aléa est bien sur  $\theta$  (contrairement à un intervalle de confiance).

## Intervalles de crédibilités (centrés) à 95% dans le modèle Beta binomial



Exemple 2: cas non conjugué

## Exemple: Prédiction de présence d'oiseaux




Une étude consiste en l'observation de la présence ou non de la linotte mélodieuse sur différents sites échantillonnés.

### Caractéristiques des sites

Sur ces différents sites sont mesurées différentes caractéristiques:

- ▶ Le nombre de vers moyens sur une surface au sol de  $1m^2$ . (Covariable 1)
- ▶ La hauteur d'herbe moyenne sur une surface au sol de  $1m^2$ . (Covariable 2)
- ▶ On calcule cette hauteur d'herbe au carré. (Covariable 3).

## Données



## Notations et modèle de régression probit

On note  $y_1, \dots, y_n$  les observations de présence (1 si on observe un oiseau, 0 sinon) sur les sites 1 à  $n$ .

On note

$$\mathbf{x}_k = \begin{pmatrix} \text{Nb. vers} & \text{Haut. herbe} & \text{Haut. herbe}^2 \\ x_{k,1} & x_{k,2} & x_{k,3} \end{pmatrix}^T$$

le vecteur des covariables sur le  $k$ -ème site ( $1 \leq k \leq n$ ).

## Notations et modèle de régression probit

On note  $y_1, \dots, y_n$  les observations de présence (1 si on observe un oiseau, 0 sinon) sur les sites 1 à  $n$ .

On note

$$\mathbf{x}_k = (\begin{smallmatrix} \text{Nb. vers} & \text{Haut. herbe} & \text{Haut. herbe}^2 \\ x_{k,1} & x_{k,2} & x_{k,3} \end{smallmatrix})^T$$

le vecteur des covariables sur le  $k$ -ème site ( $1 \leq k \leq n$ ).

On pose le modèle suivant:

$Y_k \sim \text{Bern}(p_k)$  où

$$p_k = \phi(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}) = \phi(\mathbf{x}_k^T \boldsymbol{\theta}),$$

où

- ▶  $\phi$  est la fonction de répartition d'une  $\mathcal{N}(0, 1)$ , i.e.

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{u^2}{2}} du$$

- ▶  $\boldsymbol{\theta} = \{\beta_0, \beta_1, \beta_2, \beta_3\}$  est le vecteur des paramètres à estimer.

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi \times 4^4}} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi} \times 4^4} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

### Vraisemblance

Pour un vecteur d'observations  $y_{1:k}$ , la vraisemblance

$$L(y_{1:n}|\theta) = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} \times (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

Proba. présence                      Proba. absence

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi \times 4^4}} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

### Vraisemblance

Pour un vecteur d'observations  $y_{1:k}$ , la vraisemblance

$$L(y_{1:n}|\theta) = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} \times (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

Proba. présence                      Proba. absence

### Posterior

Le posterior est donc donné par:

$$\pi(\theta|\mathbf{x}) \propto \pi(\theta)L(y_{1:n}|\theta) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T \theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

## Posterior modèle Normal-Probit

$$\pi(\theta|y_{1:n}) \propto \pi(\theta)L(y_{1:n}|\theta) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

Cette densité n'est pas standard:

- ▶ On ne sait pas calculer des espérances associées (estimateurs bayésiens);
- ▶ On pourrait approcher ces espérances par méthodes de Monte Carlo

## Posterior modèle Normal-Probit

$$\pi(\theta|y_{1:n}) \propto \pi(\theta)L(y_{1:n}|\theta) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

Cette densité n'est pas standard:

- ▶ On ne sait pas calculer des espérances associées (estimateurs bayésiens);
- ▶ On pourrait approcher ces espérances par méthodes de Monte Carlo
- ▶ Encore faut il savoir simuler!

## Posterior modèle Normal-Probit

$$\pi(\theta|y_{1:n}) \propto \pi(\theta)L(y_{1:n}|\theta) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

Cette densité n'est pas standard:

- ▶ On ne sait pas calculer des espérances associées (estimateurs bayésiens);
- ▶ On pourrait approcher ces espérances par méthodes de Monte Carlo
- ▶ Encore faut il savoir simuler!
- ▶ Le cas où le posterior ne fait pas partie d'une famille connue est très fréquent.
- ▶ L'inférence bayésienne est une motivation énorme pour les algos de simulations de loi.

## Simulation posterior modèle Normal-Probit

On veut simuler selon

$$\pi(\theta|y_{1:n}) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

## Simulation posterior modèle Normal-Probit

On veut simuler selon

$$\pi(\theta|y_{1:n}) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

Simulation par acceptation rejet

On voudrait simuler selon  $\pi(\theta|y_{1:n})$ .

## Simulation posterior modèle Normal-Probit

On veut simuler selon

$$\pi(\theta|y_{1:n}) \propto \frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

### Simulation par acceptation rejet

On voudrait simuler selon  $\pi(\theta|y_{1:n})$ .

- ▶ Idée 1: trouver une densité  $g$  selon laquelle on sait simuler et telle qu'il existe  $M > 0$  tel que

$$\forall \theta \in \mathbb{R}^4, \frac{\pi(\theta|y_{1:n})}{g(\theta)} \leq M$$

## Simulation posterior modèle Normal-Probit

On veut simuler selon

$$\pi(\theta|y_{1:n}) \propto \underbrace{\tilde{\pi}(\theta|y_{1:n})}_{\frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta}} \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

### Simulation par acceptation rejet

On voudrait simuler selon  $\pi(\theta|y_{1:n})$ .

- ▶ Idée 1: trouver une densité  $g$  selon laquelle on sait simuler et telle qu'il existe  $M > 0$  tel que

$$\forall \theta \in \mathbb{R}^4, \frac{\pi(\theta|y_{1:n})}{g(\theta)} \leq M$$

Mais  $\pi(\theta|y_{1:n})$  n'est connu qu'à une constante près!

$$\pi(\theta|y_{1:n}) = \frac{\tilde{\pi}(\theta|y_{1:n})}{\int_{\mathbb{R}^4} \pi(u) L(y_{1:n}|u) du}$$

- ▶ **Rappel** L'acceptation rejet marche toujours si on ne connaît la loi cible qu'à une constante près! (voir TD pour la preuve).

## Simulation posterior modèle Normal-Probit

On veut simuler selon

$$\pi(\theta|y_{1:n}) \propto \underbrace{\frac{1}{64\pi^2} e^{-\frac{1}{8}\theta^T\theta}}_{\tilde{\pi}(\theta|y_{1:n})} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

- ▶ Idée 2: trouver une densité  $g$  selon laquelle on sait simuler et telle qu'il existe  $M > 0$  tel que

$$\forall \theta \in \mathbb{R}^4, \frac{\tilde{\pi}(\theta|y_{1:n})}{g(\theta)} \leq M$$

## Implémentation de l'acceptation rejet

On peut par exemple prendre pour  $g$  la densité correspondant au prior ( $g(\theta) = \pi(\theta)$ ). On remarque que dans ce cas

$$\frac{\tilde{\pi}(\theta|y_{1:n})}{g(\theta)} = \frac{\pi(\theta)L(y_{1:n}|\theta)}{\pi(\theta)} = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k} \leq 1 =: M$$

**Remarque:** il existe un  $M$  optimal plus petit que 1.

## Implémentation de l'acceptation rejet

On peut par exemple prendre pour  $g$  la densité correspondant au prior ( $g(\theta) = \pi(\theta)$ ). On remarque que dans ce cas

$$\frac{\tilde{\pi}(\theta|y_{1:n})}{g(\theta)} = \frac{\pi(\theta)L(y_{1:n}|\theta)}{\pi(\theta)} = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k} \leq 1 =: M$$

**Remarque:** il existe un  $M$  optimal plus petit que 1.

Algorithme de simulation selon  $\pi(\theta|y_{1:n})$

1. On tire  $\theta_{cand} \sim \mathcal{N}(0, 4I)$
2. On tire (independamment)  $U \sim \mathcal{U}[0, 1]$
3. Si  $U < \frac{L(y_{1:n}|\theta)}{M}$ , on accepte  $\theta_{cand}$
4. Sinon on recommence

## Implémentation de l'acceptation rejet

On peut par exemple prendre pour  $g$  la densité correspondant au prior ( $g(\theta) = \pi(\theta)$ ). On remarque que dans ce cas

$$\frac{\tilde{\pi}(\theta|y_{1:n})}{g(\theta)} = \frac{\pi(\theta)L(y_{1:n}|\theta)}{\pi(\theta)} = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k} \leq 1 =: M$$

**Remarque:** il existe un  $M$  optimal plus petit que 1.

Algorithme de simulation selon  $\pi(\theta|y_{1:n})$


1. On tire  $\theta_{cand} \sim \mathcal{N}(0, 4I)$
2. On tire (independamment)  $U \sim \mathcal{U}[0, 1]$
3. Si  $U < \frac{L(y_{1:n}|\theta)}{M}$ , on accepte  $\theta_{cand}$
4. Sinon on recommence

**Remarque**, l'échantillon obtenu est tiré selon *la loi jointe* (on ne tire pas  $\beta_0$  puis  $\beta_1$ , etc...)

```
## Warning: UNRELIABLE VALUE: Future ('<none>') unexpectedly generated
## numbers without specifying argument 'seed'. There is a risk that those
## numbers are not statistically sound and the overall results might be
## To fix this, specify 'seed=TRUE'. This ensures that proper, parallel
## numbers are produced via the L'Ecuyer-CMRG method. To disable this warning,
## 'seed=NULL', or set option 'future.rng.onMisuse' to "ignore".
## Warning: UNRELIABLE VALUE: Future ('<none>') unexpectedly generated
## numbers without specifying argument 'seed'. There is a risk that those
## numbers are not statistically sound and the overall results might be
```

## Echantillon du posterior, et loi a posteriori marginales


On effectue un tirage de taille  $M = 1000$



- ▶ Les données ont bien actualisé la connaissance sur  $\theta$

## Echantillon du posterior et loi jointe

On peut regarder la loi jointe de  $(\beta_0, \beta_1 | y_{1:n})$ :



## Estimateurs bayésiens

On prend comme estimateur l'espérance **a posteriori**. De plus, on regarde l'estimation de l'intervalle

Parameter	Estimation	inf_IC95	sup_IC95
beta[0]	-0.576	-1.778926	0.6555852
beta[1]	3.231	1.603258	5.5504022
beta[2]	-0.055	-1.573656	1.4290713
beta[3]	-1.484	-3.194941	-0.2279059

## Au delà de l'acceptation rejet

Dans le cas précédent, l'espérance du temps d'attente avant une acceptation est donnée par

$$\frac{M}{\int L(y_{1:n}|\theta)\pi(\theta)d\theta}$$

## Au delà de l'acceptation rejet

Dans le cas précédent, l'espérance du temps d'attente avant une acceptation est donnée par

$$\frac{M}{\int L(y_{1:n}|\theta)\pi(\theta)d\theta}$$

Mécaniquement, cette quantité augmente quand  $n$  augmente, et l'acceptation rejet devient prohibitif.

En pratique, l'inférence Bayésienne utilisera d'autres algorithmes de simulations de loi: les algorithmes de Monte Carlo par chaîne de Markov.

# Méthodes de Monte Carlo par chaîne de Markov

Pierre Gloaguen

Avril 2020

## Rappels des cours précédents

- ▶ Méthodes de Monte Carlo pour le calcul d'espérances
- ▶ Approche par simulation de variables aléatoires i.i.d.
- ▶ Méthodes de simulation de loi (échantillons i.i.d.)
- ▶ Inférence bayésienne, technique nécessitant des algos de simulations de lois

## Modèle probit

On veut simuler selon une loi  $\pi(\theta|y_{1:n}, \mathbf{x}_{1:n})$  telle que:

$$\pi(\theta|y_{1:n}, \mathbf{x}_{1:n}) \propto e^{-\frac{1}{8}\theta^T\theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T\theta)^{y_k} (1 - \phi(\mathbf{x}_k^T\theta))^{1-y_k}$$

- ▶ Possible par acceptation rejet si  $n$  n'est pas trop grand;
- ▶ Ensuite, ne fonctionne plus **en pratique** (probabilité d'acceptation devient trop faible).
- ▶ Nécessité de définir un autre algorithme.

## Objectif du cours

- ▶ Présentation des méthodes de Monte Carlo par chaîne de Markov
- ▶ Rappel sur les chaînes de Markov (définitions)
- ▶ Théorème ergodique
- ▶ Algorithme de Metropolis Hastings
- ▶ Algorithme de Gibbs

## Rappel sur les chaînes de Markov

## Chaîne de Markov (à espace d'états fini)

Soit  $X_0$  une variable aléatoire sur  $\{1, \dots, K\}$  de loi  $\pi_0$ .

- ▶ La suite de variables aléatoires  $(X_n)_{n \geq 0}$  à valeurs dans  $\mathcal{K} = \{1, \dots, K\}$  est une chaîne de Markov si pour tout  $n \geq 1$  est pour tout suite  $(k_0, \dots, k_n)$  d'éléments de  $\mathcal{K}$ , on a :

$$\mathbb{P}(X_n = k_n | X_0 = k_0, \dots, X_{n-1} = k_{n-1}) = \mathbb{P}(X_n = k_n | X_{n-1} = k_{n-1})$$

- ▶ Cette chaîne est *homogène* si, pour  $(i, j)$  dans  $\mathcal{K} \times \mathcal{K}$ :  
 $\mathbb{P}(X_n = j | X_{n-1} = i) = \mathbb{P}(X_1 = j | X_0 = i) = P_{ij}$
- ▶ La matrice  $P = (P_{ij})$  est la **matrice de transition** de la chaîne de Markov.
- ▶ Une chaîne de Markov homogène est entièrement caractérisée par  $\pi_0$  et  $P$ .

## Loi de la chaîne

Pour  $n \geq 0$ , on note  $\pi_n$ , la loi de l'état  $X_n$ , c'est à dire le vecteur ligne

$$\pi_n = (\pi_{n,1} = \mathbb{P}(X_n = 1), \dots, \pi_{n,K} = \mathbb{P}(X_n = K)).$$

On a:

- ▶  $\mathbb{P}(X_1 = j) = \sum_{i=1}^k \mathbb{P}(X_0 = i) \times \mathbb{P}(X_1 = j | X_0 = i) = \sum_{i=1}^k \pi_{0,i} P_{ij}$  Cette relation est résumée par l'équation  $\pi_1 = \pi_0 P$
- ▶ Par récurrence, on montre que

$$P_{ij}^{(n)} := \mathbb{P}(X_n = j | X_0 = i) = (P^n)_{ij}$$

où  $P^n$  est la puissance  $n$ -ième de la matrice  $P$ .

- ▶ Ainsi:

$$\pi_n = \pi_0 P^n$$

## Mesure invariante pour $P$

Soit  $\pi$  un vecteur (ligne) de probabilité sur  $\mathcal{K}$ .

- ▶  $\pi$  est une **mesure invariante pour la chaîne de Markov de transition  $P$**  si:

$$\pi P = \pi$$

## Mesure invariante pour $P$

Soit  $\pi$  un vecteur (ligne) de probabilité sur  $\mathcal{K}$ .

- ▶  $\pi$  est une **mesure invariante pour la chaîne de Markov de transition  $P$**  si:

$$\pi P = \pi$$

- ▶ Si  $\pi_0$  est une mesure invariante pour  $P$ , alors, pour tout  $n$ ,  $\pi_n = \pi_0$ .
- ▶ Dans ce cas, les V.A.  $X_0, \dots, X_n$  sont identiquement distribuées (mais pas indépendantes!).

## Irréductibilité

Une chaîne de Markov homogène sur  $\mathcal{K}$ , de transition  $P$  est **irréductible** si

$$\forall i, j \in \mathcal{K} \times \mathcal{K}, \exists n \text{ tel que } P_{i,j}^{(n)} > 0$$

- ▶ Pour deux états de la chaîne, il est possible d'accéder de l'un à l'autre en un temps fini.

## Apérioridicité

Soit  $(X_n)_{n \geq 1}$  une chaîne de Markov homogène sur  $\mathcal{K}$ . Pour  $k \in \mathcal{K}$ ,

- ▶ La période de l'état  $k$ , notée  $d(k)$ , est le P.G.C.D. de tous les entiers  $n$  tels que  $P_{kk}^{(n)} > 0$  (avec la convention  $\text{pgcd}(\emptyset) = +\infty$ ):

$$d(j) = \text{pgcd} \left\{ n \geq 1, P_{kk}^{(n)} > 0 \right\}$$

Une chaîne est dite apériodique si pour tout  $k$  dans  $\mathcal{K}$ ,  $d(k) = 1$ .

## Apéridicité

Soit  $(X_n)_{n \geq 1}$  une chaîne de Markov homogène sur  $\mathcal{K}$ . Pour  $k \in \mathcal{K}$ ,

- ▶ La période de l'état  $k$ , notée  $d(k)$ , est le P.G.C.D. de tous les entiers  $n$  tels que  $P_{kk}^{(n)} > 0$  (avec la convention  $\text{pgcd}(\emptyset) = +\infty$ ):

$$d(j) = \text{pgcd} \left\{ n \geq 1, P_{kk}^{(n)} > 0 \right\}$$

Une chaîne est dite apéridique si pour tout  $k$  dans  $\mathcal{K}$ ,  $d(k) = 1$ .

Pour une chaîne irréductible, une condition suffisante pour être apéridique est qu'il existe un  $k \in \mathcal{K}$  tel que  $P_{kk} > 0$ .

## Théorème ergodique

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

1. Cette chaîne de Markov admet une unique mesure de probabilité invariante  $\pi$ .

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

1. Cette chaîne de Markov admet une unique mesure de probabilité invariante  $\pi$ .
2.  $X_n \xrightarrow{\text{loi}} X$  où  $X$  est une v.a. de loi  $\pi$ .

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

1. Cette chaîne de Markov admet une unique mesure de probabilité invariante  $\pi$ .
2.  $X_n \xrightarrow{\text{loi}} X$  où  $X$  est une v.a. de loi  $\pi$ .
3. Pour toute fonction  $\varphi$  intégrable par rapport à  $\pi$ , on a :

$$\frac{1}{M+1} \sum_{k=0}^M \varphi(X_k) \xrightarrow[M \rightarrow +\infty]{p.s.} \mathbb{E}_\pi[\varphi(X)].$$

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

1. Cette chaîne de Markov admet une unique mesure de probabilité invariante  $\pi$ .
2.  $X_n \xrightarrow{\text{loi}} X$  où  $X$  est une v.a. de loi  $\pi$ .
3. Pour toute fonction  $\varphi$  intégrable par rapport à  $\pi$ , on a :

$$\frac{1}{M+1} \sum_{k=0}^M \varphi(X_k) \xrightarrow[M \rightarrow +\infty]{p.s.} \mathbb{E}_\pi[\varphi(X)].$$

4. Si  $\varphi(X)$  admet un moment d'ordre supérieur à 2, on a

$$\sqrt{M} \left( \frac{1}{M+1} \sum_{k=0}^n \varphi(X_k) - \mathbb{E}_\pi[\varphi(X)] \right) \xrightarrow[M \rightarrow +\infty]{\text{Loi}} \mathcal{N}(0, \sigma^2)$$

## Théorème ergodique

Soit  $(X_n)_{n \geq 0}$  une chaîne de Markov sur  $\mathcal{K}$  de loi initiale  $\pi_0$  et de matrice de transition  $P$ . On suppose que cette chaîne est irréductible et apériodique. Alors:

1. Cette chaîne de Markov admet une unique mesure de probabilité invariante  $\pi$ .
2.  $X_n \xrightarrow{\text{loi}} X$  où  $X$  est une v.a. de loi  $\pi$ .
3. Pour toute fonction  $\varphi$  intégrable par rapport à  $\pi$ , on a :

$$\frac{1}{M+1} \sum_{k=0}^M \varphi(X_k) \xrightarrow[M \rightarrow +\infty]{p.s.} \mathbb{E}_\pi[\varphi(X)].$$

4. Si  $\varphi(X)$  admet un moment d'ordre supérieur à 2, on a

$$\sqrt{M} \left( \frac{1}{M+1} \sum_{k=0}^n \varphi(X_k) - \mathbb{E}_\pi[\varphi(X)] \right) \xrightarrow[M \rightarrow +\infty]{\text{Loi}} \mathcal{N}(0, \sigma^2)$$

Une propriété analogue reste vraie quand la chaîne de Markov est à valeurs dans un ensemble continu (typiquement,  $\mathbb{R}^d$ ).

## Conséquence et intérêt pratique du théorème ergodique

- ▶ Pour estimer  $\mathbb{E}_\pi[\varphi(X)]$ , il suffit d'être capable de simuler une chaîne de Markov apériodique et irréductible de mesure de probabilité invariante  $\pi$ .

## Conséquence et intérêt pratique du théorème ergodique

- ▶ Pour estimer  $\mathbb{E}_\pi[\varphi(X)]$ , il suffit d'être capable de simuler une chaîne de Markov apériodique et irréductible de mesure de probabilité invariante  $\pi$ .
- ▶ Il n'est pas nécessaire de savoir tirer selon  $\pi$  directement!

## Conséquence et intérêt pratique du théorème ergodique

- ▶ Pour estimer  $\mathbb{E}_\pi[\varphi(X)]$ , il suffit d'être capable de simuler une chaîne de Markov apériodique et irréductible de mesure de probabilité invariante  $\pi$ .
- ▶ Il n'est pas nécessaire de savoir tirer selon  $\pi$  directement!
- ▶ Le point 2. dit qu'*au bout d'un certain temps*, les  $X_n$  simulés pourront être considérés comme de loi  $\pi$  (mais pas indépendants)!

## Conséquence et intérêt pratique du théorème ergodique

- ▶ Pour estimer  $\mathbb{E}_\pi[\varphi(X)]$ , il suffit d'être capable de simuler une chaîne de Markov apériodique et irréductible de mesure de probabilité invariante  $\pi$ .
- ▶ Il n'est pas nécessaire de savoir tirer selon  $\pi$  directement!
- ▶ Le point 2. dit qu'*au bout d'un certain temps*, les  $X_n$  simulés pourront être considérés comme de loi  $\pi$  (mais pas indépendants!)!
- ▶ Encore faut-il être capable de construire une chaîne de Markov apériodique, irréductible, de loi invariante donnée par  $\pi$ !

## Conséquence et intérêt pratique du théorème ergodique

- ▶ Pour estimer  $\mathbb{E}_\pi[\varphi(X)]$ , il suffit d'être capable de simuler une chaîne de Markov apériodique et irréductible de mesure de probabilité invariante  $\pi$ .
- ▶ Il n'est pas nécessaire de savoir tirer selon  $\pi$  directement!
- ▶ Le point 2. dit qu'*au bout d'un certain temps*, les  $X_n$  simulés pourront être considérés comme de loi  $\pi$  (mais pas indépendants)!
- ▶ Encore faut-il être capable de construire une chaîne de Markov apériodique, irréductible, de loi invariante donnée par  $\pi$ !
- ▶ → Algorithme de Metropolis Hastings

## Remarque sur le Théorème Central Limite

- ▶ Les V.A. dans l'estimateur Monte Carlo ne sont plus indépendantes.
- ▶  $\Rightarrow$  la variance  $\sigma^2$  n'est absolument pas triviale (il ne s'agit pas de  $\mathbb{V}[\varphi(X)]$ )!
- ▶ Pas nécessairement facile à estimer!
- ▶ Ainsi, avoir un IC asymptotique sur  $\mathbb{E}_\pi[\varphi(X)]$  n'est plus du tout immédiat.

## Algorithme de Metropolis Hastings

## Réversibilité

Soit  $\pi = (\pi_1, \dots, \pi_K)$  une mesure de probabilité sur  $\mathcal{K}$  et  $(X_n)_{n \geq 0}$  une chaîne de Markov homogène de matrice de transition  $P$  et de loi initiale  $\pi_0$ .

## Réversibilité

Soit  $\pi = (\pi_1, \dots, \pi_K)$  une mesure de probabilité sur  $\mathcal{K}$  et  $(X_n)_{n \geq 0}$  une chaîne de Markov homogène de matrice de transition  $P$  et de loi initiale  $\pi_0$ .

- ▶  $\pi$  est **réversible** pour  $P$  si elle vérifie la condition d'équilibre:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, \pi_i \times P_{ij} = \pi_j \times P_{ji}$$

- ▶ *Propriété:* Si  $\pi$  est réversible pour une chaîne de Markov de transition  $P$ , alors,  $\pi$  est une mesure de probabilité invariante pour  $P$ .

## Réversibilité

Soit  $\pi = (\pi_1, \dots, \pi_K)$  une mesure de probabilité sur  $\mathcal{K}$  et  $(X_n)_{n \geq 0}$  une chaîne de Markov homogène de matrice de transition  $P$  et de loi initiale  $\pi_0$ .

- ▶  $\pi$  est **réversible** pour  $P$  si elle vérifie la condition d'équilibre:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, \pi_i \times P_{ij} = \pi_j \times P_{ji}$$

- ▶ *Propriété:* Si  $\pi$  est réversible pour une chaîne de Markov de transition  $P$ , alors,  $\pi$  est une mesure de probabilité invariante pour  $P$ .
- ▶ *Preuve* Soit  $\pi$  une mesure de probabilité réversible pour  $P$ . On a tout de suite que

$$\begin{aligned}\forall j \in \mathcal{K} \quad (\pi P)_j &= \sum_{i=1}^K \pi_i P_{ij} \\ &= \sum_{i=1}^K \pi_j P_{ji} && \text{par réversibilité} \\ &= \pi_j && \text{par propriété de } P \\ \Rightarrow \pi P &= \pi\end{aligned}$$

## Objectif de l'algorithme

- ▶ On veut simuler selon la loi  $\pi$ .
- ▶ Construire une chaîne de Markov irréductible et apériodique, de loi initiale  $\pi_0$  et de transition  $P$ , **réversible pour P**
- ▶ On va se servir pour ça d'une chaîne de Markov de transition  $Q$  (réversible et apériodique) **parcourant le même espace que  $P$**  (le support de  $\pi$ ).

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .
2. Pour  $n \geq 1$ :
  - a. On tire  $Y_n$  selon la loi  $Q_{X_{n-1}\bullet}$  (la ligne de  $Q$  donnée par  $X_{n-1}$ ).

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .
2. Pour  $n \geq 1$ :
  - a. On tire  $Y_n$  selon la loi  $Q_{X_{n-1}\bullet}$  (la ligne de  $Q$  donnée par  $X_{n-1}$ ).
  - b. On tire une loi uniforme  $U$  indépendante de  $Y_n$ .

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .

2. Pour  $n \geq 1$ :

- a. On tire  $Y_n$  selon la loi  $Q_{X_{n-1} \bullet}$  (la ligne de  $Q$  donnée par  $X_{n-1}$ ).
- b. On tire une loi uniforme  $U$  indépendante de  $Y_n$ .
- c. On calcule la quantité

$$\alpha(X_{n-1}, Y_n) = \min \left( 1, \frac{\pi_{Y_n} Q_{Y_n X_{n-1}}}{\pi_{X_{n-1}} Q_{X_{n-1} Y_n}} \right)$$

## Algorithme de Metropolis Hastings (formulation discrete)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .

2. Pour  $n \geq 1$ :

- a. On tire  $Y_n$  selon la loi  $Q_{X_{n-1} \bullet}$  (la ligne de  $Q$  donnée par  $X_{n-1}$ ).
- b. On tire une loi uniforme  $U$  indépendante de  $Y_n$ .
- c. On calcule la quantité

$$\alpha(X_{n-1}, Y_n) = \min \left( 1, \frac{\pi_{Y_n} Q_{Y_n X_{n-1}}}{\pi_{X_{n-1}} Q_{X_{n-1} Y_n}} \right)$$

- d. On pose:

$$X_n = \begin{cases} Y_n & \text{si } U \leq \alpha(X_{n-1}, Y_n) \\ X_{n-1} & \text{sinon} \end{cases}$$

## Algorithme de Metropolis Hastings (formulation discrète)

- Soit  $Q$  une matrice stochastique  $K \times K$  satisfaisant la condition suivante:

$$\forall (i, j) \in \mathcal{K} \times \mathcal{K}, Q_{ij} > 0 \Leftrightarrow Q_{ji} > 0$$

- Soit  $(X_n)_{n \geq 0}$  la suite de variables aléatoires construite ainsi:

1. On simule  $X_0$  selon  $\pi_0$ .
2. Pour  $n \geq 1$ :

- a. On tire  $Y_n$  selon la loi  $Q_{X_{n-1} \bullet}$  (la ligne de  $Q$  donnée par  $X_{n-1}$ ).
- b. On tire une loi uniforme  $U$  indépendante de  $Y_n$ .
- c. On calcule la quantité

$$\alpha(X_{n-1}, Y_n) = \min \left( 1, \frac{\pi_{Y_n} Q_{Y_n X_{n-1}}}{\pi_{X_{n-1}} Q_{X_{n-1} Y_n}} \right)$$

- d. On pose:

$$X_n = \begin{cases} Y_n & \text{si } U \leq \alpha(X_{n-1}, Y_n) \\ X_{n-1} & \text{sinon} \end{cases}$$

- **Propriété 1:**  $(X_n)_{n \geq 1}$  est une chaîne de Markov de transition  $P$  où

$$P_{ij} = Q_{ij} \alpha(i, j) \text{ si } i \neq j, \quad P_{jj} = 1 - \sum_{j \neq i} P_{ij}$$

- **Propriété 2:** De plus  $\pi$  est invariante pour  $P$ .

## Preuve

Matrice de transition  $P$

On veut montrer que:

$$P_{ij} = Q_{ij}\alpha(i, j) \text{ si } i \neq j, \quad P_{jj} = 1 - \sum_{j \neq i} P_{ij}$$

## Preuve

### Matrice de transition $P$

On veut montrer que:

$$P_{ij} = Q_{ij}\alpha(i,j) \text{ si } i \neq j, \quad P_{jj} = 1 - \sum_{j \neq i} P_{ij}$$

Soit  $i \neq j$ :

$$\begin{aligned}\mathbb{P}(X_n = j | X_{n-1} = i) &= \mathbb{P}(Y_n = j, U \leq \alpha(X_{n-1}, Y_n) | X_{n-1} = i) \\ &= \mathbb{P}(Y_n = j, U \leq \alpha(i, j) | X_{n-1} = i) \\ &= \mathbb{P}(U \leq \alpha(i, j) | X_{n-1} = i, Y_n = j) \mathbb{P}(Y_n = j | X_{n-1} = i) \\ &= Q_{ij}\alpha(i, j)\end{aligned}$$

## Preuve que $\pi$ est mesure invariante

Il suffit de montrer que  $\pi$  est réversible pour  $P$ .

Soient  $i \neq j \in \mathcal{K}$ :

## Preuve que $\pi$ est mesure invariante

Il suffit de montrer que  $\pi$  est réversible pour  $P$ .

Soient  $i \neq j \in \mathcal{K}$ :

$$\begin{aligned}\pi_i P_{ij} &= \pi_i Q_{ij} \alpha(i, j) \\&= \pi_i Q_{ij} \min \left( 1, \frac{\pi_j Q_{ji}}{\pi_i Q_{ij}} \right) \\&= \min (\pi_i Q_{ij}, \pi_j Q_{ji}) \\&= \pi_j Q_{ji} \min \left( \frac{\pi_i Q_{ij}}{\pi_j Q_{ji}}, 1 \right) \\&= \pi_j Q_{ji} \alpha(j, i) \\&= \pi_j P_{ji}\end{aligned}$$

## Algorithme dans le cas continu

Supposons qu'on veuille simuler dans  $\mathbb{R}^d$  selon une densité  $\pi$ , éventuellement connue à une constante près, c'est à dire que

$$\forall x \in \mathbb{R}^d, \pi(x) = \frac{\tilde{\pi}(x)}{\int_{\mathbb{R}^d} \tilde{\pi}(z) dz}$$

On remplace alors la matrice de transition par un *noyau de transition* sur  $\mathbb{R}^d$ , à savoir une fonction

$$\begin{aligned} q : \quad \mathbb{R}^d \times \mathbb{R}^d &\mapsto \quad \mathbb{R}_+ \\ (x, y) &\mapsto q(x, y) \geq 0 \end{aligned}$$

telle que  $\int_{\mathbb{R}^d} q(x, y) dy = 1$  (typiquement, la loi d'une marche aléatoire centrée en  $x$ ).

## Algorithme dans le cas continu

Supposons qu'on veuille simuler dans  $\mathbb{R}^d$  selon une densité  $\pi$ , éventuellement connue à une constante près, c'est à dire que

$$\forall x \in \mathbb{R}^d, \pi(x) = \frac{\tilde{\pi}(x)}{\int_{\mathbb{R}^d} \tilde{\pi}(z) dz}$$

On remplace alors la matrice de transition par un *noyau de transition* sur  $\mathbb{R}^d$ , à savoir une fonction

$$\begin{aligned} q : \quad \mathbb{R}^d \times \mathbb{R}^d &\mapsto \quad \mathbb{R}_+ \\ (x, y) &\mapsto q(x, y) \geq 0 \end{aligned}$$

telle que  $\int_{\mathbb{R}^d} q(x, y) dy = 1$  (typiquement, la loi d'une marche aléatoire centrée en  $x$ ).

Si on sait simuler, pour  $x$  fixé, selon  $q$ , et qu'on a  $q(x, y) > 0 \Leftrightarrow q(y, x) > 0$ , alors, l'algorithme de Metropolis reste valide en remplaçant  $\pi$  par  $\tilde{\pi}$  et  $Q$  par  $q$ .

## Algorithme dans le cas continu

Supposons qu'on veuille simuler dans  $\mathbb{R}^d$  selon une densité  $\pi$ , éventuellement connue à une constante près, c'est à dire que

$$\forall x \in \mathbb{R}^d, \pi(x) = \frac{\tilde{\pi}(x)}{\int_{\mathbb{R}^d} \tilde{\pi}(z) dz}$$

On remplace alors la matrice de transition par un *noyau de transition* sur  $\mathbb{R}^d$ , à savoir une fonction

$$\begin{aligned} q : \quad \mathbb{R}^d \times \mathbb{R}^d &\mapsto \quad \mathbb{R}_+ \\ (x, y) &\mapsto q(x, y) \geq 0 \end{aligned}$$

telle que  $\int_{\mathbb{R}^d} q(x, y) dy = 1$  (typiquement, la loi d'une marche aléatoire centrée en  $x$ ).

Si on sait simuler, pour  $x$  fixé, selon  $q$ , et qu'on a  $q(x, y) > 0 \Leftrightarrow q(y, x) > 0$ , alors, l'algorithme de Metropolis reste valide en remplaçant  $\pi$  par  $\tilde{\pi}$  et  $Q$  par  $q$ .

- Le ratio ne nécessite pas la constante de normalisation car

$$\frac{\tilde{\pi}(y)}{\tilde{\pi}(x)} = \frac{\pi(y)}{\pi(x)}$$

Exemple 2: cas non conjugué

## Exemple: Prédiction de présence d'oiseaux




Une étude consiste en l'observation de la présence ou non de la linotte mélodieuse sur différents sites échantillonnés.

### Caractéristiques des sites

Sur ces 300 sites sont mesurées différentes caractéristiques:

- ▶ Le nombre de vers moyens sur une surface au sol de  $1m^2$ . (Covariable 1)
- ▶ La hauteur d'herbe moyenne sur une surface au sol de  $1m^2$ . (Covariable 2)
- ▶ On calcule cette hauteur d'herbe au carré. (Covariable 3).

## Données



## Notations et modèle de régression probit

On note  $y_1, \dots, y_n$  les observations de présence (1 si on observe un oiseau, 0 sinon) sur les sites 1 à  $n$ .

On note

$$\mathbf{x}_k = \begin{pmatrix} \text{Nb. vers} & \text{Haut. herbe} & \text{Haut. herbe}^2 \\ x_{k,1} & x_{k,2} & x_{k,3} \end{pmatrix}^T$$

le vecteur des covariables sur le  $k$ -ème site ( $1 \leq k \leq n$ ).

## Notations et modèle de régression probit

On note  $y_1, \dots, y_n$  les observations de présence (1 si on observe un oiseau, 0 sinon) sur les sites 1 à  $n$ .

On note

$$\mathbf{x}_k = \begin{pmatrix} \text{Nb. vers} & \text{Haut. herbe} & \text{Haut. herbe}^2 \\ x_{k,1} & x_{k,2} & x_{k,3} \end{pmatrix}^T$$

le vecteur des covariables sur le  $k$ -ème site ( $1 \leq k \leq n$ ).

On pose le modèle suivant:

$Y_k \sim \text{Bern}(p_k)$  où

$$p_k = \phi(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}) = \phi(\mathbf{x}_k^T \boldsymbol{\theta}),$$

où

- ▶  $\phi$  est la fonction de répartition d'une  $\mathcal{N}(0, 1)$ , i.e.

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{u^2}{2}} du$$

- ▶  $\boldsymbol{\theta} = \{\beta_0, \beta_1, \beta_2, \beta_3\}$  est le vecteur des paramètres à estimer.

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi \times 4^4}} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi} \times 4^4} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

### Vraisemblance

Pour un vecteur d'observations  $y_{1:k}$ , la vraisemblance

$$L(y_{1:k} | \theta) = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} \times (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

Proba. présence                      Proba. absence

## Modèle Bayésien

### Prior sur $\theta$

Comme a priori sur  $\theta$ , on choisit une normale avec une grande variance  $\theta \stackrel{\text{prior}}{\sim} \mathcal{N}(0, 4I)$ , donc

$$\pi(\theta) = \frac{1}{\sqrt{2\pi} \times 4^4} e^{-\frac{1}{8}\theta^T \theta}$$

où  $I$  est la matrice Identité (ici  $4 \times 4$ )

### Vraisemblance

Pour un vecteur d'observations  $y_{1:k}$ , la vraisemblance

$$L(y_{1:k}|\theta) = \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} \times (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

Proba. présence                      Proba. absence

### Posterior

Le posterior est donc donné par:

$$\pi(\theta|y_{1:n}) \propto \pi(\theta)L(y_{1:n}|\theta) \propto e^{-\frac{1}{8}\theta^T \theta} \prod_{k=1}^n \phi(\mathbf{x}_k^T \theta)^{y_k} (1 - \phi(\mathbf{x}_k^T \theta))^{1-y_k}$$

## Algorithme de Metropolis Hastings

La loi stationnaire cible est  $\pi(\mathbf{y}|\theta)$ . Pour  $n = 300$ , l'acceptation rejet vu au cours précédent fonctionnera très mal en pratique.


## Algorithme de Metropolis Hastings

La loi stationnaire cible est  $\pi(\mathbf{y}|\theta)$ . Pour  $n = 300$ , l'acceptation rejet vu au cours précédent fonctionnera très mal en pratique.

On fait un algorithme de Metropolis Hastings avec comme loi de proposition une marche aléatoire dans  $\mathbb{R}^4$ , de matrice de covariance  $\tau^2 \times I_4$ .


## Résultat d'un algorithme lancé depuis un point de départ

- On choisit  $\beta^{(0)} = (0, 0, 0, 0)$  et  $\tau^2 = 0.1$ , on lance 1000 itérations.




## Sensibilité au point de départ

Il faut toujours vérifié la sensibilité au point de départ!



## Influence de $\tau^2$



## Influence de $\tau^2$

### Taux d'acceptation dans l'algorithme

$\tau^2$	Taux d'acceptation
0.001	0.781
0.010	0.515
0.100	0.147
1.000	0.013

## Influence de $\tau^2$

### Taux d'acceptation dans l'algorithme

$\tau^2$	Taux d'acceptation
0.001	0.781
0.010	0.515
0.100	0.147
1.000	0.013

### Autocorrelation dans les chaînes

Correlation entre empirique entre  $\beta_1^n$  et  $\beta_1^{(n+1)}$

$\tau^2$	Autocorrelation
0.001	0.9993751
0.010	0.9917581
0.100	0.9835038
1.000	0.9864433

## Reduction de l'autocorrelation

En pratique, on choisira une fraction des points. On appelle cela le **thinning**.

## Reduction de l'autocorrelation

En pratique, on choisira une fraction des points. On appelle cela le **thinning**.

Autocorrélation en prenant un point sur 100.

$\tau^2$	Autocorrelation
0.001	0.8092081
0.010	0.2395796
0.100	0.1502224
1.000	0.3861150

## Estimation de la loi



Les premières valeurs n'ont aucune raison d'être tirées selon la loi cible.

En pratique, on les supprimera. On appelle cela le **burn-in**.

## Estimation de la loi

Les premières valeurs n'ont aucune raison d'être tirées selon la loi cible.

En pratique, on les supprimera. On appelle cela le **burn-in**.



## Autres algorithmes MCMC

## Echantillonneur de Gibbs

- ▶ Utile quand  $\theta$  est en grande dimension;
- ▶ On suppose qu'on sait simuler selon les loi conditionnelles de  $\theta$

## Echantillonneur de Gibbs

- ▶ Utile quand  $\theta$  est en grande dimension;
- ▶ On suppose qu'on sait simuler selon les loi conditionnelles de  $\theta$
- ▶ Soit  $X$  un vecteur aléatoire en dimension  $d$   $X = (X^{(1)}, \dots, X^{(d)})$ .
- ▶ On note  $X^{(-\ell)} = (X^{(1)}, \dots, X^{(\ell-1)}, X^{(\ell+1)}, X^{(d)})$ ,
- ▶ Si on sait simuler la variable aléatoire  $X^{(\ell)}|X^{(-\ell)}$ , l'algo est le suivant:
  1. Prendre  $X_0 = (X_0^{(1)}, \dots, X_0^{(d)})$  tiré selon une loi initiale.
  2. Pour  $k \geq 1$ :
    - 2.1 Tirer  $\ell$  uniformément dans  $\{1, \dots, d\}$ ;
    - 2.2 Simuler  $Y$  selon la loi  $X^{(\ell)}|\{X^{(-\ell)} = X_{k-1}^{(-\ell)}\}$
    - 2.3 Poser  $X_k = (X_{k-1}^{(1)}, \dots, X_{k-1}^{(\ell-1)}, Y, X_{k-1}^{(\ell+1)}, X_{k-1}^{(d)})$

## Propriété de l'échantillonneur de Gibbs

- ▶ L'échantillonneur de Gibbs est équivalent à un algorithme de Metropolis Hastings où la quantité  $\alpha$  est toujours égale à 1,
- ▶ C'est à dire un Metropolis Hastings où on n'accepte tous les candidats!
- ▶ Algorithme utile dès que la simulation des lois conditionnelles est faisable.
- ▶ Si les lois conditionnelles induisent une matrice de transition (ou un noyau) de Markov irréductible et apériodique, alors le théorème ergodique s'applique.